Homework 2 Bozza Definitiva

Matricola: 359445
Siervo Riccardo

Gennaio 2025

Sommario

Dichiarazioni e Note Metodologiche

Come richiesto, fornisco di seguito le dichiarazioni sulla paternità del lavoro e le note relative alle scelte implementative adottate:

- **Differenze rispetto alla bozza precedente:** Questa bozza contiene due modifiche sostanziali rispetto alla precedente: la prima è che è stato corretto e integrato il passaggio sulla previsione sulla griglia di W e la seconda è che è stato completato il punto 5 facoltativo dell'esercizio 1.
- **Paternità del lavoro:** Si precisa che, nonostante l'adozione della prima persona plurale ("noi") per scelta stilistica, il lavoro è frutto di un'elaborazione interamente personale.
- **Utilizzo di strumenti IA:** L'utilizzo di strumenti di Intelligenza Artificiale è stato circoscritto esclusivamente alle seguenti finalità strumentali:
  - *Miglioramento formale:* Per la revisione della forma sintattica e della fluidità narrativa.
  - *Automazione grafica:* Per la produzione di elementi grafici ripetitivi e la formattazione di output tabellari.
- **Riferimenti al codice:**
  - *Procedure MCMC standard:* Non abbiamo appesantito il testo con la sintassi R per l'aggiornamento di μ, Σ, π (già discussi in precedenza nell'homework 1 le procedure standard MCMC)
  - *Focus implementativo:* Abbiamo invece dedicato un approfondimento specifico (Sezione 7.5) alla logica di traduzione in codice dell'Algoritmo di Viterbi, data la sua maggiore complessità.

1 Analisi esplorativa e definizione del modello

L'analisi esplorativa dei dati (Figura 1) mostra la presenza di strutture spaziali evidenti: i punti geograficamente vicini tendono a presentare valori simili di log(PM10), formando dei cluster riconoscibili. Inoltre, il passaggio da regioni con valori più elevati a regioni con valori più bassi avviene in modo graduale. Questo comportamento suggerisce che il fenomeno osservato sia caratterizzato da una forte dipendenza spaziale, ovvero che

le osservazioni non siano indipendenti tra loro ma correlate in funzione della distanza euclidea.

In presenza di tale dipendenza, un modello naturale è quello basato sui Processi Gaussiani. L'idea di fondo è che, dato un insieme di n punti spaziali $s_1, \ldots, s_n$, il vettore delle osservazioni $(Y(s_1), \ldots, Y(s_n))$ possa essere modellato come una variabile aleatoria normale multivariata, la cui matrice di covarianza dipende dalla distanza tra i punti. È proprio la struttura della covarianza che ci permette di incorporare formalmente la dipendenza osservata: se due punti sono vicini, la loro covarianza sarà elevata; se sono lontani, questa decrescerà fino a diventare trascurabile.

Coerentemente con queste osservazioni, modelliamo il log(PM10) nel punto s attraverso la seguente specificazione:

$$Y(s) = \mu + \beta_1 s_1 + \beta_2 s_2 + W(s) + \epsilon(s) \tag{1}$$

In questa equazione distinguiamo tre componenti:

Trend: Il termine $\mu + \beta_1 s_1 + \beta_2 s_2$ cattura la tendenza globale del fenomeno legata alle coordinate.

Processo Spaziale: $W(s)$ è il processo gaussiano latente a media zero, $W(s) \sim GP(0, C(h; \phi))$, che cattura la struttura di correlazione spaziale residua. Per la funzione di covarianza assumiamo una forma esponenziale isotropica[1]:

$$C(h; \phi) = \sigma^2 \exp(-\phi h)$$

dove h è la distanza tra due punti e ϕ è il parametro di decadimento: valori più alti di ϕ indicano che la correlazione spaziale si esaurisce più velocemente. Questa scelta esponenziale riflette quanto osservato nella mappa: la similitudine è forte a breve raggio ma diminuisce allontanandosi.

Errore: Infine, $\epsilon(s)$ rappresenta il "rumore bianco" indipendente, $\epsilon(s) \overset{iid}{\sim} N(0, \tau^2)$. Questo termine è fondamentale perché cattura la variabilità locale non spiegata dal processo spaziale (ad esempio l'errore di misura), distinguendola dalla struttura spaziale continua $W(s)$.

[1] Si assume che il processo sia stazionario debole di secondo ordine. Trattandosi di un Processo Gaussiano, tale condizione è sufficiente a implicare la stazionarietà in senso forte. In virtù della stazionarietà del primo ordine, la media è costante; senza perdita di generalità, essa viene posta pari a zero dato che la componente di trend è già stata considerata. La stazionarietà del secondo ordine rende la covarianza invariante per traslazioni, ovvero dipendente solo dal vettore separazione tra i punti. Infine, si introduce l'ulteriore ipotesi di isotropia: la funzione di covarianza risulta pertanto invariante anche rispetto alla direzione (rotazioni), dipendendo esclusivamente dalla norma euclidea del vettore distanza $||\mathbf{h}||$.

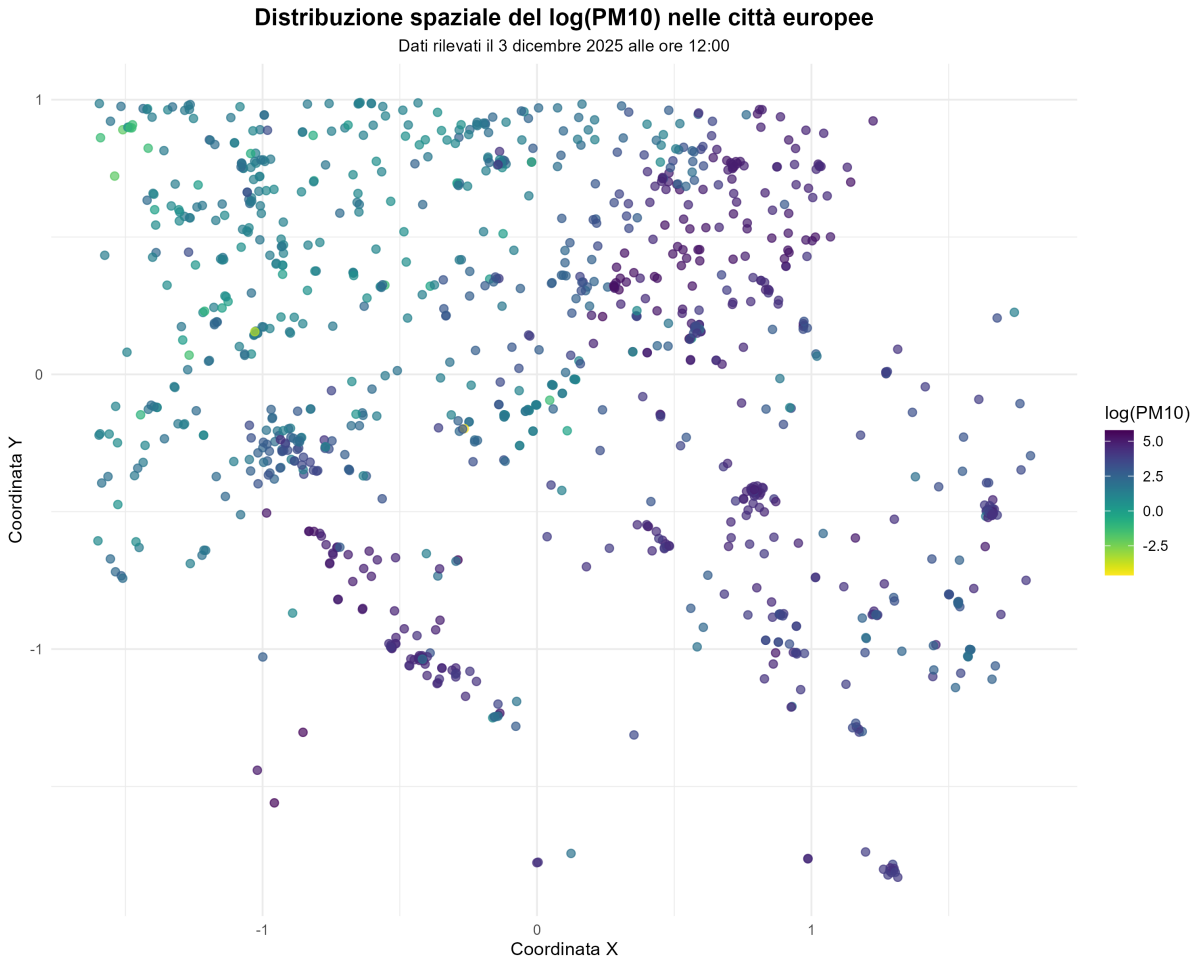


Figura 1: Distribuzione spaziale del log(PM10) nelle città europee. I colori rappresentano l'intensità del valore osservato: si notano evidenti cluster spaziali che suggeriscono una correlazione positiva tra località vicine.

2 Stima Bayesiana e Derivazione dell'Algoritmo MCMC

Definito il modello nel punto precedente, l'obiettivo si sposta ora sulla stima congiunta dei parametri ignoti e delle variabili latenti. Data la complessità del modello gerarchico, che include un processo spaziale latente W di dimensione n, non è possibile ottenere una soluzione analitica in forma chiusa per la distribuzione a posteriori congiunta.

Per questo motivo, adottiamo un approccio computazionale basato su Markov Chain Monte Carlo (MCMC). Nello specifico, implementiamo un Gibbs Sampler, che ci permette di campionare sequenzialmente ogni parametro dalla propria distribuzione condizionata completa (full conditional), fissando gli altri ai valori correnti. Laddove la full conditional non sia riconoscibile come una distribuzione nota (come nel caso del parametro di decadimento spaziale ϕ), inseriremo all'interno del Gibbs uno step di Metropolis-Hastings.

2.1 Definizione del Modello Gerarchico e Priors

Per un sottoinsieme di n osservazioni, il modello può essere riscritto in notazione matriciale come:

$$y = X\beta + W + \epsilon$$

dove:

- y è il vettore delle osservazioni log(PM10) di dimensione $n \times 1$.
- $X \in \mathbb{R}^{n\times 3}$ è la matrice del disegno con riga i-esima $(1, s_{1i}, s_{2i})$, che include l'intercetta e le coordinate spaziali.
- $\beta = (\mu, \beta_1, \beta_2)^T$ è il vettore dei coefficienti di regressione.
- $W \sim N_n(0, \Sigma_w)$ è il processo spaziale, con matrice di covarianza definita da $[\Sigma_w]_{ij} = \sigma^2 \exp(-\phi h_{ij})$, dove $h_{ij} = \|s_i - s_j\|$.
- $\epsilon \sim N_n(0, \tau^2 I_n)$ è l'errore di misura indipendente.

In forma compatta, la verosimiglianza condizionata ai parametri è:

$$y \mid \beta, W, \tau^2 \sim N_n(X\beta + W, \tau^2 I_n)$$

Per completare la specificazione Bayesiana, assegniamo le seguenti distribuzioni a priori (priors), scelte per essere debolmente informative:

- Coefficienti di regressione: $\beta \sim N_3(0, 10^4 I_3)$
- Varianza spaziale: $\sigma^2 \sim IG(1, 1)$
- Varianza dell'errore: $\tau^2 \sim IG(1, 1)$
- Decadimento spaziale: $\phi \sim U\left(\frac{3}{\text{dist}_{\max}}, \frac{3}{\text{dist}_{\min}}\right)$

Dove $\text{dist}_{\min}$ e $\text{dist}_{\max}$ rappresentano le distanze euclidee minima (non nulla) e massima osservate nel dataset. La densità a posteriori congiunta risulta quindi proporzionale al prodotto della verosimiglianza e delle priors:

$$f(\beta, \sigma^2, \tau^2, \phi, W \mid y) \propto f(y \mid \beta, W, \tau^2)\, f(W \mid \phi, \sigma^2)\, f(\beta)\, f(\tau^2)\, f(\sigma^2)\, f(\phi)$$

2.2 Derivazione delle Full Conditionals

Di seguito deriviamo le full conditionals complete necessarie per l'implementazione del Gibbs Sampler.

Full Conditional di W (Effetto Spaziale Latente)

Isoliamo dalla posteriori congiunta tutti i termini che dipendono da W. Abbiamo il contributo della verosimiglianza (dove W appare nella media) e il contributo della prior del processo spaziale:

$$f(W \mid \ldots) \propto \frac{1}{|\Sigma_w|^{1/2}} \exp\left\{-\frac{1}{2\tau^2}(y - X\beta - W)^T(y - X\beta - W)\right\} \exp\left\{-\frac{1}{2}W^T\Sigma_w^{-1}W\right\}$$

Poiché stiamo condizionando rispetto agli altri parametri (σ^2 e ϕ sono fissati, quindi $|\Sigma_w|$ è costante), quindi lo rimuoviamo (è una costante moltiplicativa). Definiamo il residuo parziale $R = y - X\beta$ e sviluppiamo i calcoli nell'esponenziale:

$$f(W \mid \ldots) \propto \exp\left\{-\frac{1}{2\tau^2}(R - W)^T(R - W) - \frac{1}{2}W^T\Sigma_w^{-1}W\right\}$$

Espandiamo il termine quadratico $(R-W)^T(R-W)$:

$$(R-W)^T(R-W) = R^TR - W^TR - R^TW + W^TW$$

Essendo il risultato uno scalare, vale $R^TW = (R^TW)^T = W^TR$, quindi i termini misti si sommano in $-2W^TR$. L'espressione diventa:

$$\propto \exp\left\{-\frac{1}{2\tau^2}(R^TR - 2W^TR + W^TW) - \frac{1}{2}W^T\Sigma_w^{-1}W\right\}$$

Rimuovendo i termini che non dipendono da W (come R^TR) e raccogliendo i termini rispetto a W:

$$\propto \exp\left\{-\frac{1}{2}\left[-\frac{2}{\tau^2}W^TR + \frac{1}{\tau^2}W^TW + W^T\Sigma_w^{-1}W\right]\right\}$$

Riorganizziamo in forma quadratica matriciale:

$$\propto \exp\left\{-\frac{1}{2}\left[W^T\left(\frac{1}{\tau^2}I_n + \Sigma_w^{-1}\right)W - 2W^T\left(\frac{1}{\tau^2}R\right)\right]\right\}$$

Confrontiamo questa espressione con il kernel di una normale multivariata $N(\mu, V)$, la cui densità è proporzionale a $\exp\{-\frac{1}{2}(W-\mu)^TV^{-1}(W-\mu)\} \propto \exp\{-\frac{1}{2}[W^TV^{-1}W - 2W^TV^{-1}\mu]\}$. Uguagliando i termini quadratici e lineari:

- Precisione: $V_w^{-1} = \frac{1}{\tau^2}I_n + \Sigma_w^{-1} \implies V_w = \left(\frac{1}{\tau^2}I_n + \Sigma_w^{-1}\right)^{-1}$
- Media: $V_w^{-1}\mu_w = \frac{1}{\tau^2}R \implies \mu_w = V_w\frac{y - X\beta}{\tau^2}$

Pertanto, la full conditional è una Normale Multivariata:

$$\boxed{W \mid \ldots \sim N_n(\mu_w, V_w)}$$

Full Conditional di β (Coefficienti di Regressione)

Isoliamo i termini dipendenti da β. Abbiamo la verosimiglianza e la prior normale:

$$f(\beta \mid \ldots) \propto \exp\left\{-\frac{1}{2\tau^2}(y - X\beta - W)^T(y - X\beta - W)\right\}\exp\left\{-\frac{1}{2}\beta^T(10^4 I_3)^{-1}\beta\right\}$$

Definiamo $y^* = y - W$ per semplificare la notazione e sviluppiamo il prodotto:

$$(y^* - X\beta)^T(y^* - X\beta) = (y^*)^Ty^* - (y^*)^TX\beta - \beta^TX^Ty^* + \beta^TX^TX\beta$$

Analogamente a prima, i termini misti si accorpano in $-2\beta^TX^Ty^*$ in quanto scalari. Rimuovendo i termini costanti rispetto a β:

$$\propto \exp\left\{-\frac{1}{2\tau^2}\left[-2\beta^TX^Ty^* + \beta^TX^TX\beta\right] - \frac{1}{2}\beta^T\left(\frac{1}{10^4}I_3\right)\beta\right\}$$

Raccogliamo i termini quadratici e lineari rispetto a β:

$$\propto \exp\left\{-\frac{1}{2}\left[\beta^T\left(\frac{1}{\tau^2}X^TX + \frac{1}{10^4}I_3\right)\beta - 2\beta^T\left(\frac{1}{\tau^2}X^Ty^*\right)\right]\right\}$$

Riconoscendo il kernel normale multivariato, otteniamo:

- Varianza: $V_\beta = \left(\frac{1}{\tau^2}X^TX + \frac{1}{10^4}I_3\right)^{-1}$
- Media: $\mu_\beta = V_\beta\left(\frac{1}{\tau^2}X^T(y - W)\right)$

$$\boxed{\beta \mid \ldots \sim N_3(\mu_\beta, V_\beta)}$$

Full Conditional di τ^2 (Varianza dell'Errore)

Consideriamo la verosimiglianza (dove τ^2 appare come varianza) e la prior Inverse Gamma.

$$f(\tau^2 \mid \ldots) \propto (\tau^2)^{-n/2} \exp\left\{-\frac{1}{2\tau^2}\|y - X\beta - W\|^2\right\} \times (\tau^2)^{-(1+1)} \exp\left(-\frac{1}{\tau^2}\right)$$

Sommando gli esponenti di τ^2 e raccogliendo i termini nell'esponenziale:

$$\propto (\tau^2)^{-n/2-2} \exp\left\{-\frac{1}{\tau^2}\left(\frac{1}{2}\sum_{i=1}^{n}(y_i - \mu - \beta_1 s_{1i} - \beta_2 s_{2i} - w_i)^2 + 1\right)\right\}$$

Riconosciamo il kernel di una Inverse Gamma $IG(A, B)$ dove $f(x) \propto x^{-(A+1)}e^{-B/x}$. Identifichiamo i parametri:

- Shape: $A = 1 + \frac{n}{2}$
- Scale: $B = 1 + \frac{1}{2}\|y - X\beta - W\|^2$

$$\boxed{\tau^2 \mid \ldots \sim IG\left(1 + \frac{n}{2},\, 1 + \frac{1}{2}\|y - X\beta - W\|^2\right)}$$

Full Conditional di σ^2 (Varianza Spaziale)

Utilizziamo la relazione $\Sigma_w = \sigma^2 R_\phi$, dove R_ϕ è la matrice di correlazione spaziale. La full conditional dipende dalla densità del processo W e dalla prior.

$$f(\sigma^2 \mid \ldots) \propto f(W \mid \phi, \sigma^2)\, f(\sigma^2)$$

Espandiamo la densità di W, notando che il determinante si fattorizza come $|\sigma^2 R_\phi| = (\sigma^2)^n |R_\phi|$:

$$f(W \mid \phi, \sigma^2) \propto [(\sigma^2)^n |R_\phi|]^{-1/2} \exp\left(-\frac{1}{2} W^T (\sigma^2 R_\phi)^{-1} W\right) \propto (\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2} W^T R_\phi^{-1} W\right)$$

($|R_\phi|$ non dipende da σ^2 e viene assorbito nella costante). Moltiplicando per la prior $(\sigma^2)^{-2}\exp(-1/\sigma^2)$:

$$\propto (\sigma^2)^{-n/2-2} \exp\left\{-\frac{1}{\sigma^2}\left(1 + \frac{1}{2} W^T R_\phi^{-1} W\right)\right\}$$

Anche qui riconosciamo una Inverse Gamma:

$$\boxed{\sigma^2 \mid \ldots \sim IG\left(1 + \frac{n}{2},\, 1 + \frac{1}{2} W^T R_\phi^{-1} W\right)}$$

Full Conditional di ϕ (Decadimento Spaziale)

La full conditional per ϕ coinvolge la densità di W (poiché la matrice R_ϕ e il suo determinante dipendono da ϕ) e la prior uniforme.

$$f(\phi \mid \ldots) \propto f(W \mid \phi, \sigma^2) f(\phi)$$

$$f(\phi \mid \ldots) \propto \det(R_\phi)^{-1/2} \exp\left\{ -\frac{1}{2\sigma^2} W^T R_\phi^{-1} W \right\} \cdot \mathbf{1}_{\left(\frac{3}{\text{dist}_{\max}}, \frac{3}{\text{dist}_{\min}}\right)}(\phi)$$

Questa espressione non è riconducibile ad alcuna famiglia parametrica nota a causa della complessa dipendenza di R_ϕ^{-1} e $\det(R_\phi)$ da ϕ. Pertanto, per aggiornare ϕ all'interno del Gibbs Sampler, utilizzeremo un passo Metropolis-Hastings con proposta adattiva, lavorando sulla scala logaritmica per garantire la stabilità numerica. L'espressione in questa scala diventa:

$$\log f(\phi \mid \ldots) = -\frac{1}{2} \log(\det(R_\phi)) - \frac{1}{2\sigma^2} w^T R_\phi^{-1} w$$

Questa equazione è valida solo se ϕ rispetta i vincoli della prior uniforme, ovvero se $\frac{3}{d_{\max}} < \phi < \frac{3}{d_{\min}}$.

2.2.1 Dettagli Computazionali: Stabilità Numerica e Decomposizione di Cholesky

L'aggiornamento del parametro di decadimento spaziale ϕ tramite algoritmo Metropolis-Hastings rappresenta il passaggio computazionalmente più critico dell'intera procedura. Il calcolo del rapporto di accettazione richiede infatti la valutazione ripetuta della densità $f(w \mid \phi, \sigma^2)$, che dipende dal determinante della matrice di correlazione $|R_\phi|$ e dalla forma quadratica $w^T R_\phi^{-1} w$.

Calcolare queste quantità direttamente (tramite le funzioni standard `det()` e `solve()`) è sconsigliato in ambito spaziale. Quando la distanza tra i punti è ridotta, le righe della matrice di covarianza diventano quasi linearmente dipendenti (diventando ricche di zeri), rendendo R_ϕ mal condizionata e portando facilmente a instabilità numerica e grossolani errori di arrotondamento nell'inversione.

Per garantire robustezza e velocità, abbiamo implementato la decomposizione di Cholesky. Essendo R_ϕ simmetrica e definita positiva (per definizione matrice di covarianza), essa può essere fattorizzata univocamente come:

$$R_\phi = LL^T$$

dove L è una matrice triangolare inferiore. L'utilizzo di L offre due vantaggi determinanti:

Calcolo del Determinante

Sfruttando le proprietà dei determinanti, sappiamo che $|R_\phi| = |LL^T| = |L||L^T|$. Poiché L è una matrice triangolare, il suo determinante è semplicemente il prodotto degli elementi sulla diagonale principale: $|L| = \prod_{i=1}^{n} L_{ii}$. Di conseguenza, il determinante della matrice di correlazione è:

$$|R_\phi| = \left(\prod_{i=1}^{n} L_{ii} \right)^2$$

Passando ai logaritmi per evitare problemi di overflow o underflow (tipici quando si moltiplicano molti numeri piccoli), il calcolo si riduce a una semplice somma:

$$\log |R_\phi| = 2 \sum_{i=1}^{n} \log(L_{ii})$$

Calcolo della Forma Quadratica

Il termine $w^T R_\phi^{-1} w$ viene calcolato senza mai invertire esplicitamente la matrice R_ϕ, evitando così le instabilità tipiche dell'inversione di matrici mal condizionate. Sostituendo la fattorizzazione $R_\phi = LL^T$ nell'espressione originale e sfruttando la proprietà dell'inversa di un prodotto, $(AB)^{-1} = B^{-1}A^{-1}$, otteniamo:

$$w^T R_\phi^{-1} w = w^T (LL^T)^{-1} w = w^T (L^{-1})^T L^{-1} w$$

Raggruppando i termini, si osserva che l'espressione equivale al prodotto scalare $z^T z$ (ovvero la norma euclidea al quadrato $\|z\|^2$), dove definiamo il vettore ausiliario come $z = L^{-1} w$.

Dal punto di vista computazionale, il vettore z non si ottiene calcolando L^{-1}, operazione che sarebbe inutile e costosa, bensì risolvendo il sistema lineare associato:

$$Lz = w$$

Poiché L è una matrice triangolare inferiore, questo sistema viene risolto in modo efficiente e meno oneroso[2] rispetto a invertire una matrice. Il calcolo finale si riduce quindi a:

$$w^T R_\phi^{-1} w = z^T z = \sum z_i^2$$

2.3 Inizializzazione dei Parametri

Sebbene la teoria delle catene di Markov garantisca la convergenza alla distribuzione stazionaria indipendentemente dal punto di partenza, una scelta oculata dei valori iniziali $\theta^{(0)}$ è cruciale nella pratica. Un'inizializzazione coerente con la struttura dei dati permette infatti di ridurre drasticamente la fase di burn-in e di evitare che l'algoritmo rimanga intrappolato in regioni a bassa densità di probabilità nelle prime iterazioni.

Per questo motivo, invece di affidarci a valori casuali, adottiamo questa strategia:

Coefficienti di Trend (β)

Per determinare il punto di partenza dei coefficienti β, ricorriamo a un'idea intuitiva: facciamo finta, per un attimo, che la componente spaziale latente W non esista. Sotto questa assunzione semplificatrice, il modello complesso si riduce a una classica regressione lineare con errori indipendenti:

$$y \approx X\beta + \epsilon$$

[2]Questo deriva dal metodo risolutivo per sistemi definiti da matrici triangolari inferiori:la sostituzione in avanti (forward substitution). E' un algoritmo iterativo che calcola la prima incognita direttamente dalla prima equazione e ne sostituisce il valore nella successiva per determinare la seconda, procedendo a cascata fino all'ultima variabile. Questo approccio evita il calcolo dell'inversa, riducendo la complessità

In questo scenario ridotto, la stima migliore per i coefficienti è data dalla soluzione analitica dei minimi quadrati ordinari. Pertanto, impostiamo:

$$\beta^{(0)} = (X^T X)^{-1} X^T y$$

Questa operazione ci permette di avviare la catena con un trend che cattura già la variabilità macroscopica del fenomeno.

Processo Spaziale (W)

Coerentemente con l'assunzione fatta al punto precedente, il vettore delle variabili latenti viene inizializzato come vettore nullo:

$$W^{(0)} = \mathbf{0}_n$$

Varianze (τ^2 e σ^2)

Calcoliamo i residui empirici iniziali rispetto al trend stimato, ossia $e = y - X\beta^{(0)}$. La varianza campionaria di tali residui, S_e^2, rappresenta una stima della variabilità totale non spiegata dalle coordinate. Pertanto, inizializziamo la varianza dell'errore come $\tau^{2(0)} = 0.5 \cdot S_e^2$ e la varianza spaziale come $\sigma^{2(0)} = 0.5 \cdot S_e^2$, ovvero ripartendo equamente la varianza campionaria tra le due varianze.

Decadimento Spaziale (ϕ)

Per il parametro ϕ, non avendo informazioni a priori forti sulla scala della correlazione oltre ai vincoli geometrici, scegliamo il punto medio del supporto definito dalla prior uniforme:

$$\phi^{(0)} = \frac{1}{2}\left(\frac{3}{\text{dist}_{\max}} + \frac{3}{\text{dist}_{\min}}\right)$$

Questo valore centrale evita di favorire inizialmente strutture di dipendenza troppo locali o troppo estese, garantendo una buona mobilità dell'algoritmo Metropolis-Hastings nelle prime fasi.

2.4 Dettagli Implementativi: Metropolis-Hastings su Scala Logaritmica

L'aggiornamento del parametro di decadimento spaziale ϕ ha richiesto una cura particolare. Un'implementazione ingenua di un Random Walk Metropolis sulla scala originale, con proposta $\phi^* \sim N(\phi^{(b-1)}, \eta^2)$, ha mostrato severe criticità in fase di test. Utilizzando i parametri di adattamento standard ($A = 500, D = 1000, c = 50$), la catena esibiva un comportamento dicotomico patologico: tassi di accettazione prossimi allo 0 (con varianze della proposta elevate) o prossimi all'1 (con varianze minime), senza mai stabilizzarsi su un mixing ottimale.

Diagnosi del Problema

L'inefficienza è imputabile alla geometria del dominio rispetto alla distribuzione a posteriori. Il dominio teorico imposto dalla prior uniforme è estremamente vasto, $\phi \in [\approx$

$0.76, 4074]$, mentre la massa di probabilità a posteriori si concentra in un intervallo ristretto (circa $[1.5, 6.3]$). In questo contesto, una proposta additiva $\phi^* = \phi + \varepsilon$ soffre di un problema di scala: un passo ε adeguato per esplorare le code della prior risulta essere di ordini di grandezza eccessivo per esplorare la regione ad alta densità, portando a un rifiuto quasi certo. Viceversa, un passo piccolo adatto alla posterior intrappola la catena in un comportamento di tipo "diffusivo" estremamente lento.

Soluzione: Riparametrizzazione Logaritmica

Per risolvere il problema, abbiamo operato una trasformazione di variabile, definendo $\theta = \log(\phi)$ ed eseguendo il passo Metropolis direttamente su θ. Questo comporta due vantaggi fondamentali:

- **Compressione del Dominio:** L'intervallo di definizione viene mappato in $\theta \in [-0.28, 8.31]$. La regione ad alta densità a posteriori occupa ora una frazione significativamente più ampia dello spazio totale, facilitando l'esplorazione da parte della catena.
- **Proposte Moltiplicative:** Un passo additivo sulla scala logaritmica, $\theta^* = \theta + \varepsilon$ con $\varepsilon \sim N(0, \eta^2)$, corrisponde a una proposta moltiplicativa sulla scala originale:

  $$\phi^* = \phi \cdot e^{\varepsilon}$$

  Questo garantisce che l'ampiezza del salto sia proporzionale al valore corrente del parametro, rispettando la natura di parametro di scala di ϕ e permettendo di esplorare tutto il dominio.

Formalmente, campionare θ richiede di valutare la densità target trasformata, che include lo Jacobiano della trasformazione $|d\phi/d\theta| = e^{\theta} = \phi$ [3]. Il rapporto di accettazione diventa:

$$\begin{aligned}\alpha &= \min\left\{1, \frac{f(\phi^* \mid \dots) \cdot \phi^*}{f(\phi^{(b-1)} \mid \dots) \cdot \phi^{(b-1)}}\right\} \\ &= \min\left\{1, \exp\left(\left[\log f(\phi^* \mid \dots) + \log \phi^*\right] - \left[\log f(\phi^{(b-1)} \mid \dots) + \log \phi^{(b-1)}\right]\right)\right\}\end{aligned}$$

dove il termine aggiuntivo ϕ compensa la distorsione introdotta dalla scala logaritmica.

Calibrazione dell'Adattamento

Passando alla scala logaritmica, l'adattamento della varianza della proposta η^2 è risultato molto più stabile. Tuttavia, i parametri di tuning suggeriti per la scala originale ($A = 500, D = 1000, c = 50$) si sono rivelati troppo conservativi. Abbiamo trovato empiricamente che un adattamento più reattivo, con parametri:

$$A = 2, \quad D = 100, \quad c = 10$$

permette alla varianza η^2 di convergere rapidamente verso un valore che garantisce un tasso di accettazione più vicino a quello ottimale.

[3] Formalmente, questo termine deriva dalla regola di cambiamento di variabile per le densità di probabilità:

$$f_{\Theta}(\theta) = f_{\Phi}(\phi(\theta)) \left|\frac{d\phi(\theta)}{d\theta}\right|$$

Dato che la trasformazione inversa è $\phi(\theta) = \exp(\theta)$, lo Jacobiano risulta $\left|\frac{d\phi}{d\theta}\right| = e^{\theta} = \phi$.

3 Diagnostica MCMC e Analisi dei Risultati a Posteriori

La validità dell'inferenza bayesiana condotta tramite algoritmi MCMC riposa su due pilastri fondamentali: la convergenza della catena alla distribuzione stazionaria e l'efficienza del campionamento. Quest'ultima è strettamente legata al concetto di buon mixing, inteso come la capacità dell'algoritmo di esplorare in modo efficace e rapido la regione ad alta densità a posteriori. In presenza di un buon mixing, le iterazioni successive risultano debolmente dipendenti e la correlazione seriale decresce velocemente, garantendo una copertura approfondita e rappresentativa dello spazio parametrico rilevante.

3.1 Impostazione del MCMC e Thinning

L'algoritmo Gibbs Sampler (integrato con il passo Metropolis per ϕ) è stato eseguito per un totale di $B = 125.000$ iterazioni. Di queste, le prime 25.000 sono state scartate come fase di burn-in. Tale operazione è necessaria per eliminare l'influenza dei valori iniziali $\theta^{(0)}$ e assicurare che la catena abbia raggiunto la regione di alta densità probabilistica prima di iniziare la raccolta dei campioni.

Un'analisi preliminare delle catene grezze ha evidenziato una marcata autocorrelazione tra iterazioni successive per diversi parametri. In particolare, l'ispezione delle funzioni di autocorrelazione (ACF) ha mostrato una dipendenza seriale non trascurabile anche a lag relativamente elevati. Alla luce di queste evidenze empiriche, si è reso necessario introdurre una procedura di thinning (sottocampionamento), al fine di ridurre la ridondanza informativa tra campioni consecutivi.

In ottica conservativa, è stata salvata una iterazione ogni $k = 50$. Tutte le analisi e i risultati riportati nelle sezioni successive fanno riferimento esclusivamente alle catene così trattate. Il campione finale utilizzato per l'inferenza risulta quindi composto da $N = 2.000$ osservazioni.

3.2 Analisi della Convergenza (Traceplots)

La valutazione visiva della convergenza tramite i traceplots (Figura 2 e Figura 3) conferma la stabilità dell'algoritmo per tutti i parametri monitorati ($\beta, \sigma^2, \tau^2, \phi$). Le catene esibiscono il caratteristico andamento stazionario: esse oscillano rapidamente attorno a un valore medio stabile, senza mostrare trend. L'assenza di blocchi o salti improvvisi è un indicatore che l'algoritmo ha esplorato adeguatamente il supporto della distribuzione a posteriori (buon mixing).

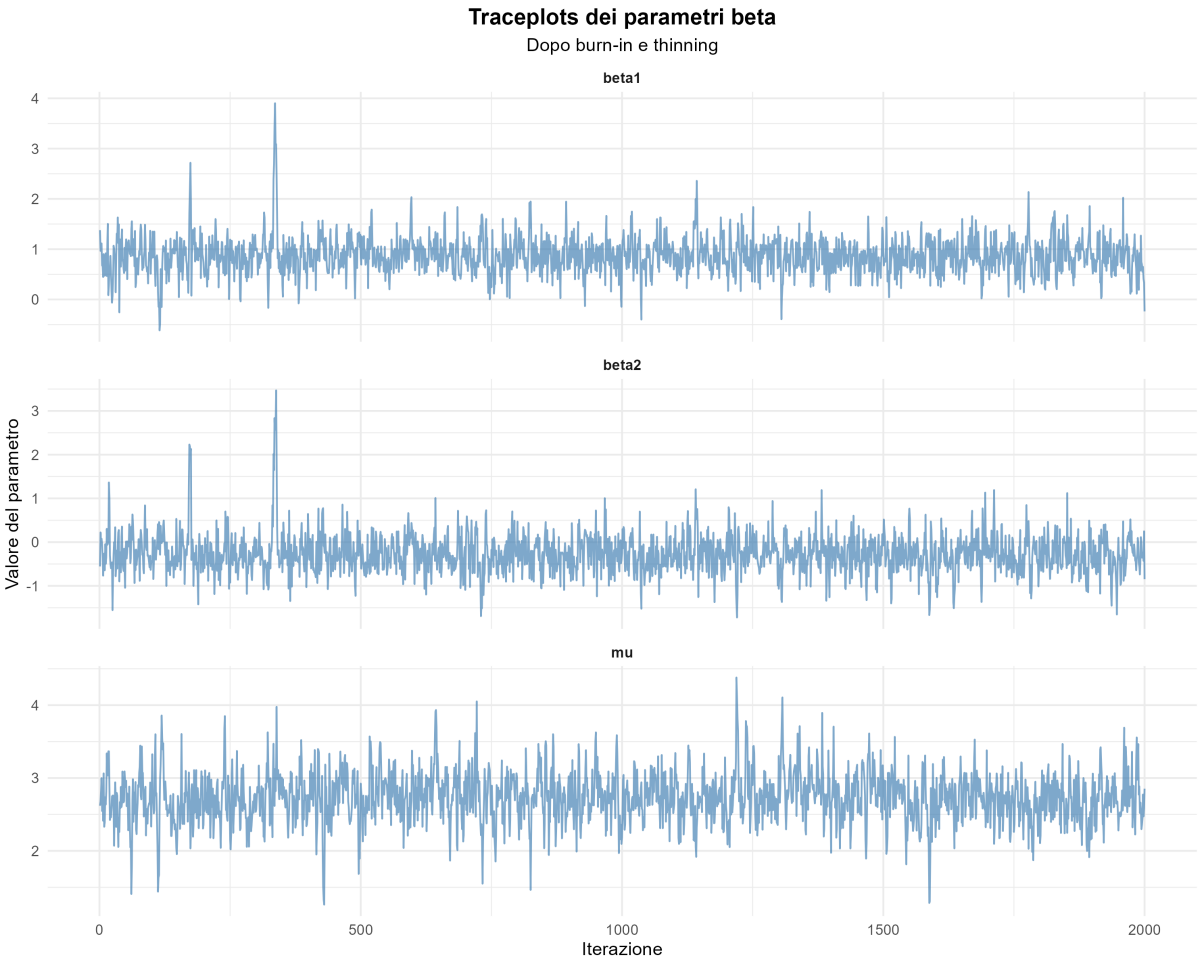


Figura 2: Traceplots dei parametri beta dopo burn-in e thinning.

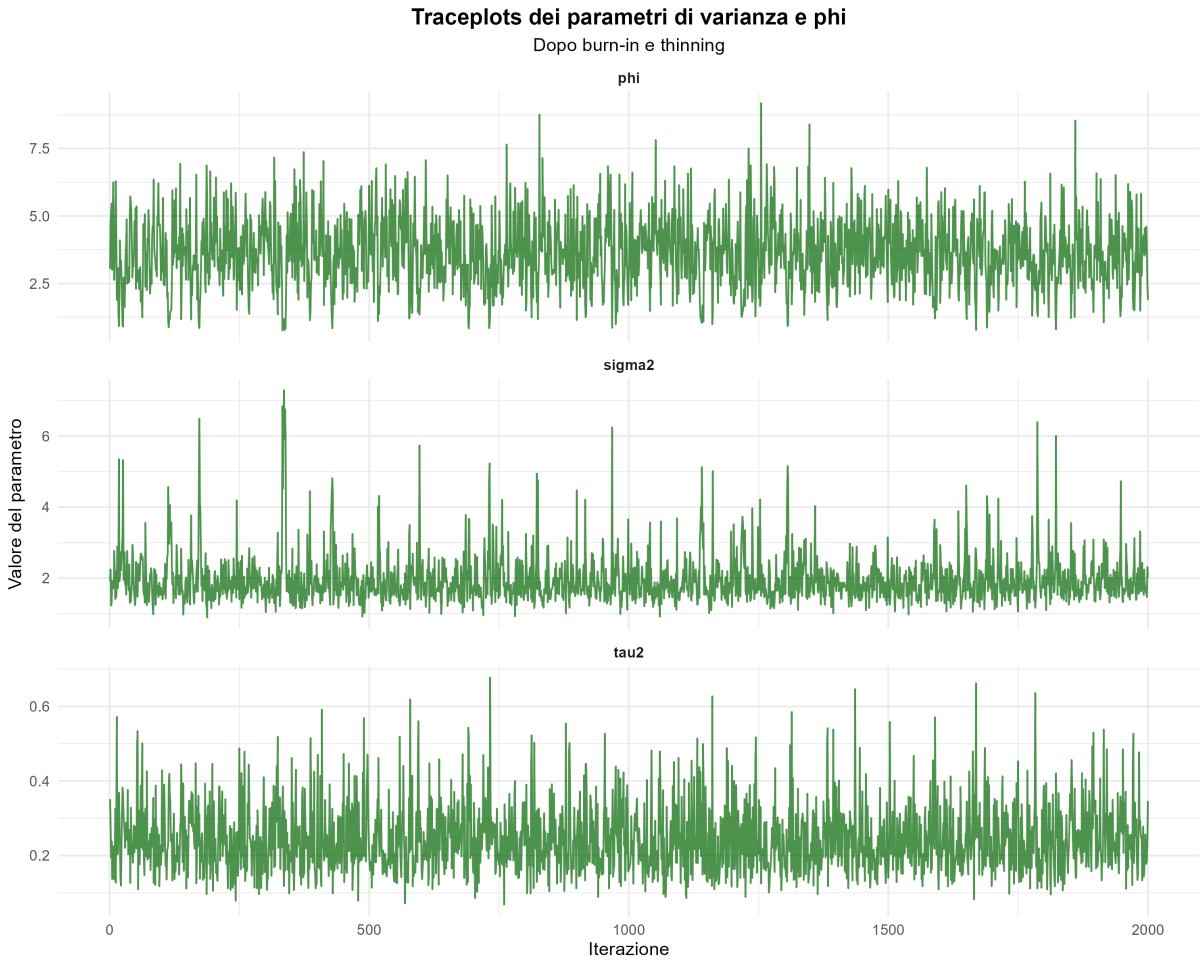


Figura 3: Traceplots dei parametri di varianza e phi dopo burn-in e thinning.

3.3 Efficienza del Campionamento: Autocorrelazione ed ESS

L'efficacia della strategia di thinning è corroborata dalle funzioni di autocorrelazione (ACF, Figura 4 e Figura 5). I correlogrammi mostrano un rapido decadimento della correlazione seriale, che rientra nelle bande di significatività entro pochi lag per tutti i parametri.

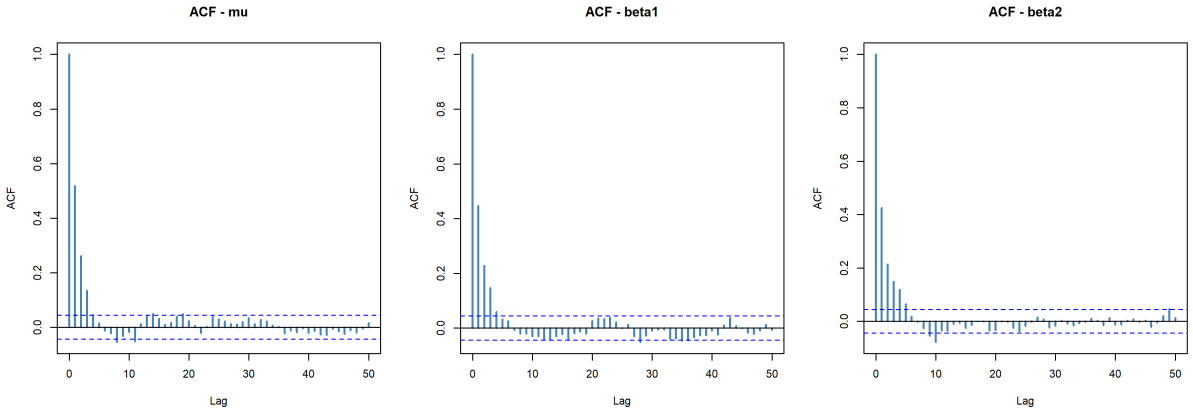


Figura 4: Funzioni di autocorrelazione (ACF) per i parametri beta.

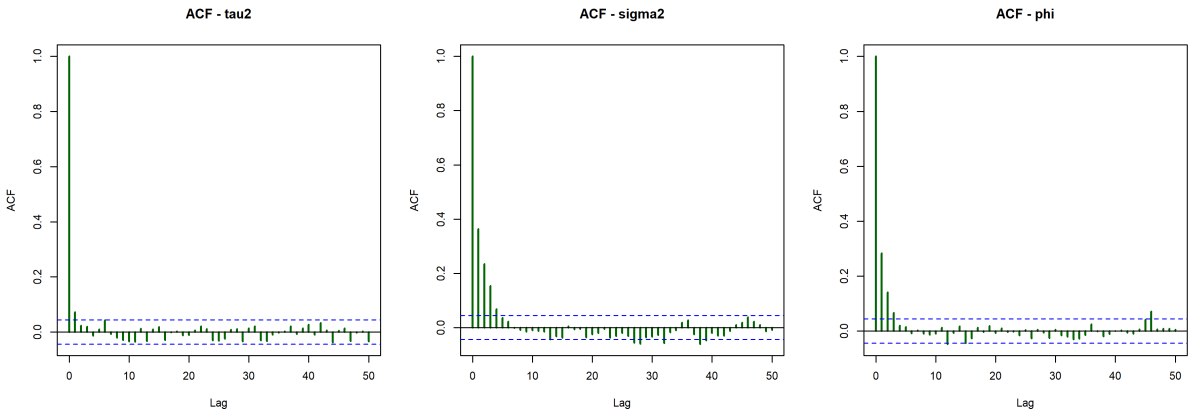


Figura 5: Funzioni di autocorrelazione (ACF) per le varianze e phi.

Per quantificare formalmente la precisione delle stime, calcoliamo l'Effective Sample Size (ESS). L'ESS stima il numero di campioni indipendenti che apporterebbero la stessa quantità di informazione contenuta nella nostra catena correlata. La sua formulazione è data da:

$$ESS = \frac{N}{1 + 2\sum_{k=1}^{\infty} \rho_k}$$

dove N è la dimensione del campione (2000) e ρ_k è l'autocorrelazione al lag k. Un valore di ESS basso suggerisce che la catena, pur essendo lunga, esplora lo spazio lentamente. Come riportato nella Tabella 1, tutti i parametri presentano un ESS ampiamente superiore alla soglia di sicurezza (generalmente > 400 per stime affidabili).

Tabella 1: Effective Sample Size (ESS) ed Efficienza

Parametro	**N campioni**	**ESS**	**Efficienza (%)**
μ	2000	713.5	35.68
β_1	2000	700.5	35.03
β_2	2000	615.9	30.79
τ^2	2000	1728.5	86.43
σ^2	2000	677.9	33.89
ϕ	2000	977.3	48.86

Inoltre, il tasso di accettazione medio per il passo Metropolis di ϕ si attesta al 19.52%. Questo valore è vicino all'ottimo teorico (circa 25%), confermando il successo della strategia adattiva su scala logaritmica descritta nella sezione precedente.

3.4 Stime a Posteriori e Interpretazione

Le distribuzioni marginali a posteriori (Figura 6 e Figura 7) risultano unimodali e ben comportate, con forme regolari e prive di multimodalità. Questo suggerisce che il modello è ben identificato dai dati e che l'algoritmo MCMC ha esplorato in modo adeguato la distribuzione a posteriori, rendendo affidabili le stime puntuali e gli intervalli di credibilità ottenuti. Nella Tabella 2 riportiamo le statistiche di sintesi (media, deviazione standard) e gli intervalli di credibilità al 95%.

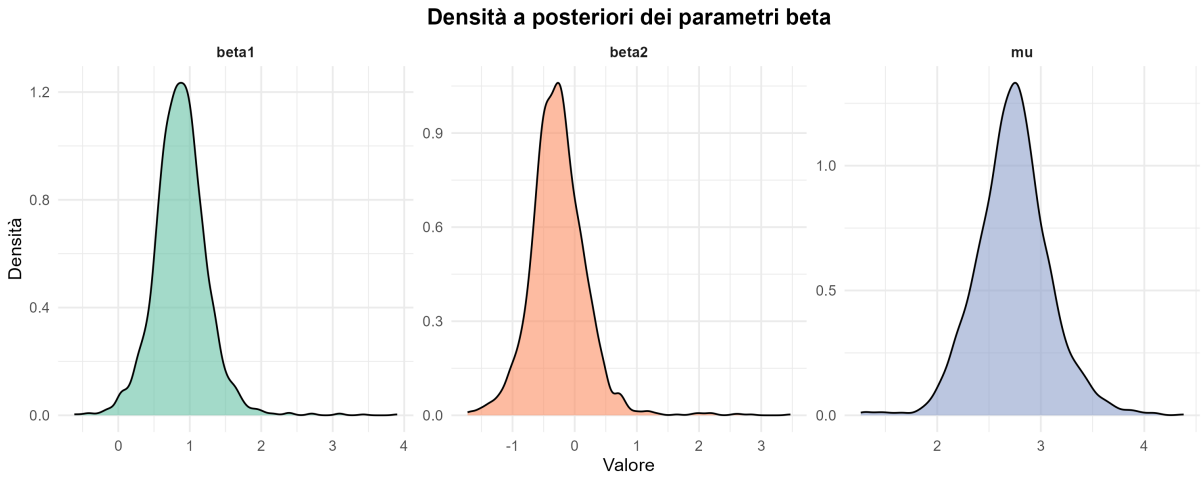


Figura 6: Densità a posteriori dei parametri beta.

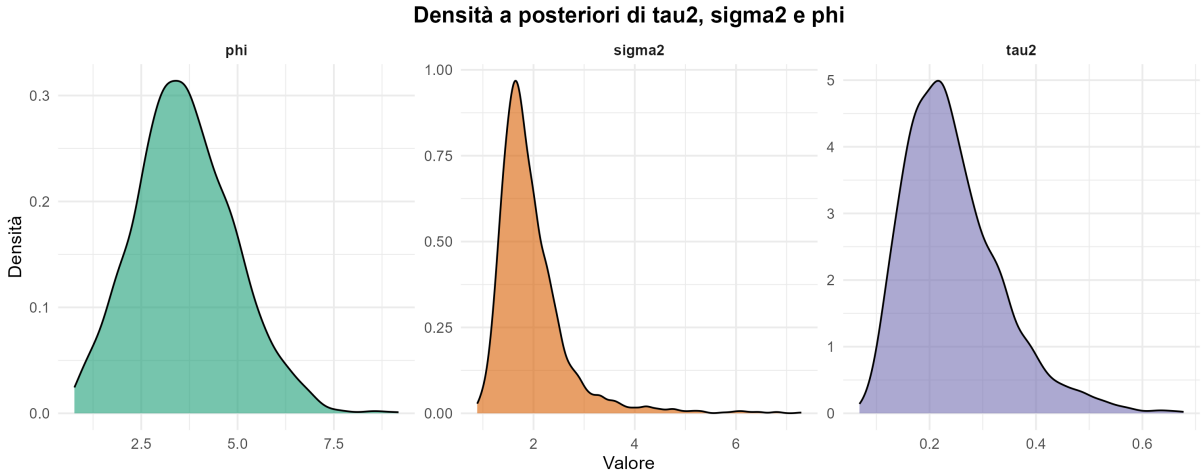


Figura 7: Densità a posteriori di tau2, sigma2 e phi.

Tabella 2: Stime dei parametri e Intervalli di Credibilità al 95%

Parametro	**Media Post.**	**Dev. Std.**	**IC 2.5%**	**IC 97.5%**
Trend				
μ	2.734	0.352	2.055	3.466
β_1 (Coord. X)	0.875	0.369	0.165	1.616
β_2 (Coord. Y)	-0.263	0.453	-1.082	0.645
Varianza e Spazio				
τ^2	0.245	0.092	0.113	0.473
σ^2	1.959	0.694	1.168	3.798
ϕ (Decadimento)	3.633	1.283	1.251	6.314

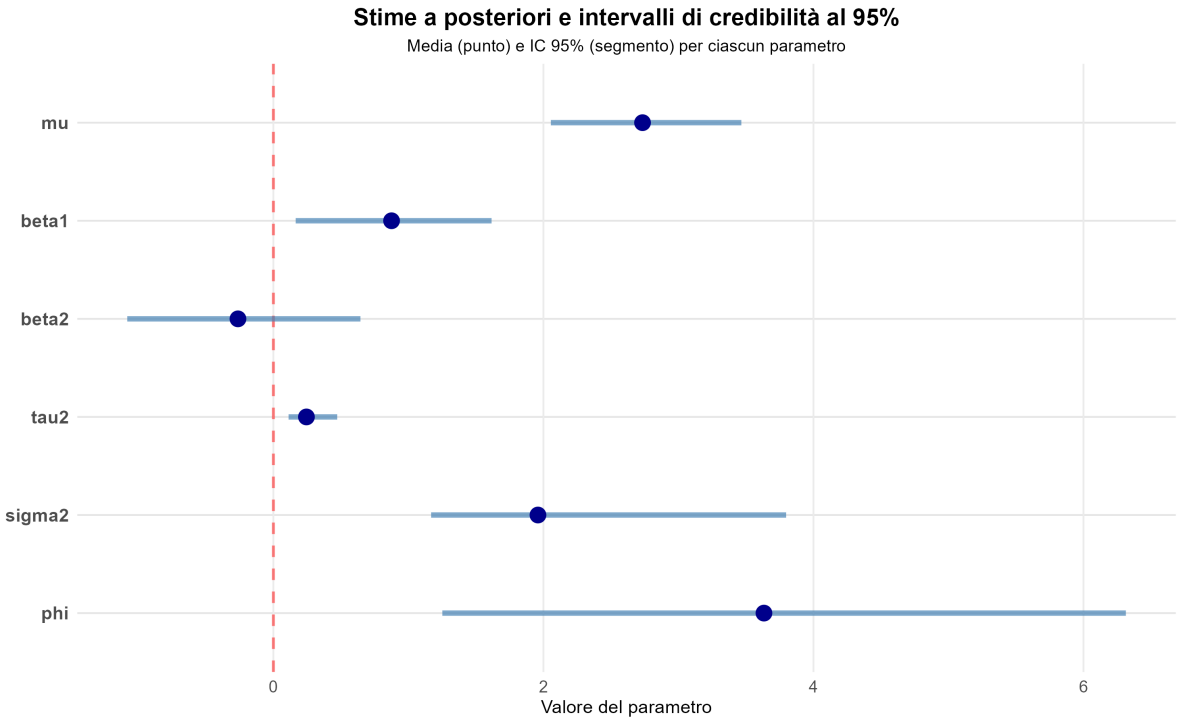


Figura 8: Stime a posteriori e intervalli di credibilità al 95%.

3.4.1 Discussione dei Risultati

Analisi dei Coefficienti di Regressione

L'esame delle stime a posteriori evidenzia un contributo differenziato delle covariate spaziali. Nello specifico, l'intervallo di credibilità al 95% per β_1 non include lo zero, denotando un'elevata probabilità a posteriori dell'esistenza di un effetto positivo — seppur di entità contenuta — della coordinata longitudinale (X) sui livelli di log(PM10). Al contrario, l'intervallo associato a β_2 comprende lo zero: questo suggerisce che l'effetto lineare della coordinata Y non è supportato dall'evidenza empirica e può essere considerato trascurabile nel contesto del modello corrente.

Giustificazione del Processo Spaziale

Per quanto riguarda la struttura di variabilità, emerge con chiarezza che la varianza del processo spaziale (σ^2) risulta nettamente superiore alla varianza dell'errore indipendente (τ^2). Poiché la varianza quantifica la dispersione dei dati attorno al trend medio, questo risultato indica che la variabilità residua non è semplice rumore bianco, ma è prevalentemente strutturata nello spazio. Tale evidenza è una prima giustificazione a posteriori per l'introduzione del Processo Gaussiano: un modello privo di questa componente latente avrebbe fallito nel catturare una porzione dominante dell'informazione contenuta nei dati. Ulteriori giustificazioni emergeranno nei paragrafi successivi.

3.5 Validazione della Robustezza: Analisi su Catene con Inizializzazioni Diverse

A ulteriore garanzia della qualità dell'inferenza e per escludere che la convergenza osservata fosse condizionata da una specifica scelta dei valori di partenza $\theta^{(0)}$, è stata condotta un'analisi di sensibilità rispetto all'inizializzazione.

L'algoritmo MCMC è stato rieseguito su diverse catene, inizializzate deliberatamente in punti disparati e distanti dello spazio dei parametri. Il confronto tra le diverse traiettorie ha evidenziato una convergenza globale: nonostante i punti di partenza differenti, tutte le catene sono migrate verso la stessa regione ad alta densità di probabilità, producendo distribuzioni a posteriori statisticamente indistinguibili.

3.6 Analisi della Funzione di Covarianza Spaziale

La funzione di covarianza isotropica $C(h;\theta)(\theta = (\sigma^2, \phi))$ è l'elemento costitutivo fondamentale che definisce la distribuzione di probabilità sullo spazio delle funzioni ammissibili. In un contesto pienamente bayesiano, i parametri σ^2 e ϕ sono trattati come variabili aleatorie con una distribuzione congiunta a posteriori $p(\sigma^2, \phi \mid \mathbf{y})$; di conseguenza, la funzione di covarianza stessa $C(h)$ eredita tale aleatorietà, divenendo anche essa una variabile aleatoria la cui incertezza deve essere quantificata.

Per caratterizzare questa incertezza, abbiamo adottato un approccio Monte Carlo, costruendo una griglia discreta di distanze $H = \{h_1, \ldots, h_{100}\}$ che copre il range spaziale di interesse ovvero da 0 a alla distanza massima (3.95). A partire dai campioni della posteriore $\{(\sigma_i^2, \phi_i)\}_{i=1}^N$ generati dall'MCMC, abbiamo costruito una matrice di calcolo M di dimensione $N \times 100$, il cui elemento generico è definito come:

$$M_{ij} = C^{(i)}(h_j) = \sigma_i^2 \exp(-\phi_i h_j) \quad \text{per } i = 1, \ldots, N \text{ e } j = 1, \ldots, 100$$

La struttura di questa matrice riflette la dualità tra la definizione funzionale teorica e la stima statistica computazionale:

- **Analisi per Righe (Traiettorie Funzionali):** Fissando una riga i, i parametri σ_i^2 e ϕ_i rimangono costanti mentre varia la distanza h_j lungo le colonne. Ogni riga rappresenta quindi una singola realizzazione deterministica della funzione di covarianza, condizionata a uno specifico stato visitato dalla catena Markoviana. L'insieme delle righe visualizza il ventaglio delle possibili forme funzionali compatibili con i dati osservati.

- **Analisi per Colonne (Integrazione Monte Carlo):** Fissando una colonna j, la distanza h_j è bloccata. Scorrendo le righe, i parametri variano secondo la loro distribuzione a posteriori congiunta. È su questa dimensione che opera l'integrazione Monte Carlo: l'insieme dei valori nella colonna j costituisce un campione empirico della variabile aleatoria scalare $C(h_j)$.

Di conseguenza, il calcolo della media campionaria lungo la colonna corrisponde all'approssimazione numerica dell'integrale del valore atteso per quel punto specifico dello spazio:

$$\underbrace{\frac{1}{N}\sum_{i=1}^{N} C(h_j; \sigma_i^2, \phi_i)}_{\text{Media di colonna}} \approx \mathbb{E}[C(h_j) \mid \mathbf{y}] = \underbrace{\int C(h_j;\theta) p(\theta|\mathbf{y}) d\theta}_{\text{Integrale Monte Carlo}}$$

Applicando questa logica, abbiamo ricostruito la curva media a posteriori e le bande di incertezza (Figura 9). La linea solida scura rappresenta la stima puntuale della covarianza (media di colonna), mentre l'area ombreggiata delimita l'intervallo di credibilità al 95%, ottenuto calcolando i quantili empirici (2.5% e 97.5%) per ogni distanza h_j.

Il grafico mostra chiaramente come la correlazione spaziale sia molto forte a distanze ridotte ($h \approx 0$) e decada rapidamente, diventando trascurabile per distanze superiori a $h \approx 1$. L'ampiezza delle bande riflette l'incertezza congiunta sulla varianza totale del processo e sulla velocità di decadimento.

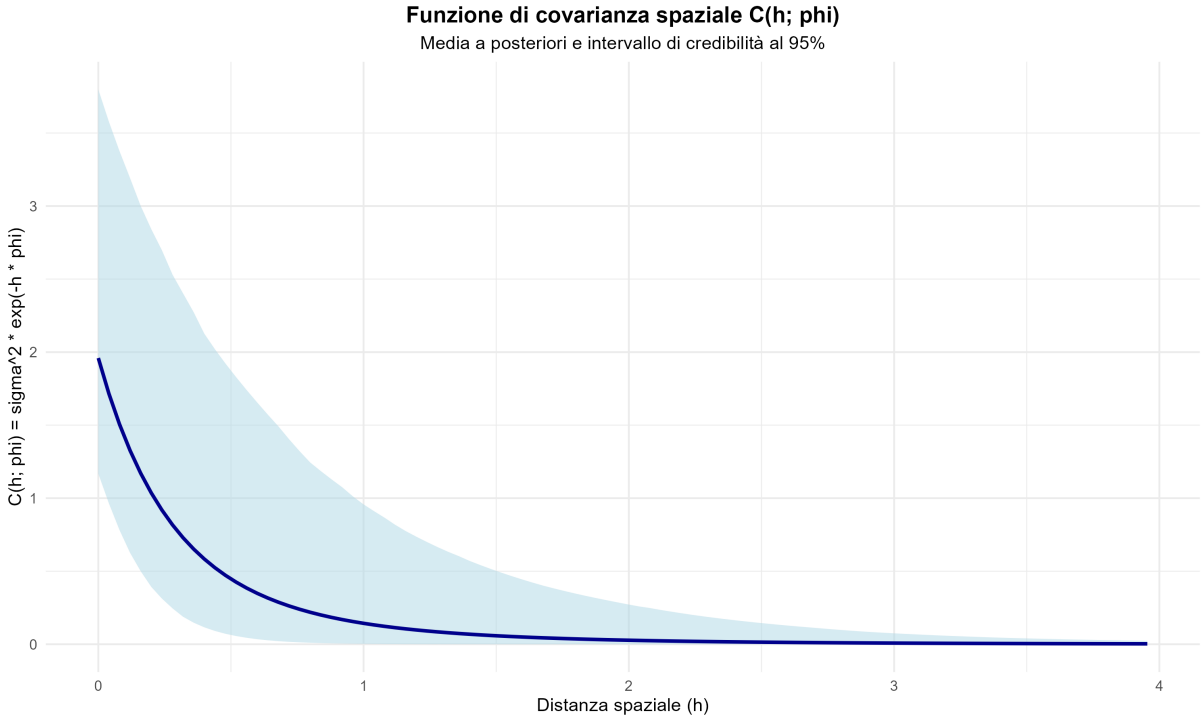


Figura 9: Funzione di covarianza spaziale $C(h; \phi)$. Media a posteriori e intervallo di credibilità al 95%.

3.7 Analisi della Distribuzione Spaziale del Processo Latente $W(s)$

L'analisi si conclude con l'esame della distribuzione a posteriori del processo latente $W(s)$ nello spazio, visualizzata attraverso le mappe della media a posteriori e degli estremi dell'intervallo di credibilità al 95% (Figura 10).

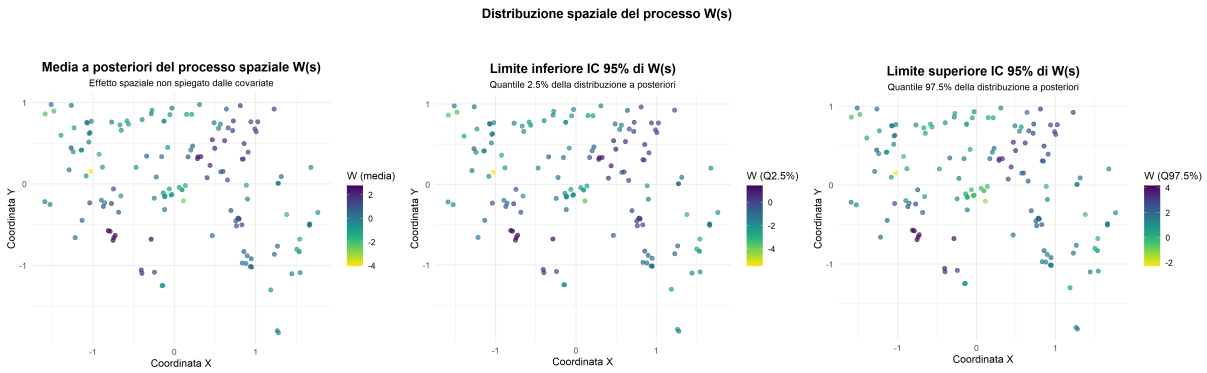


Figura 10: Distribuzione spaziale del processo latente $W(s)$: media a posteriori e limiti dell'intervallo di credibilità al 95%.

Dall'osservazione di questi grafici emerge un risultato inequivocabile: il processo latente assume valori significativamente distanti dallo zero nella quasi totalità del dominio spaziale. Gli intervalli di credibilità associati ai singoli punti, infatti, raramente includono l'origine. Questa evidenza empirica costituisce la validazione definitiva della struttura gerarchica adottata: se il processo spaziale fosse stato trascurabile (ovvero i suoi valori appiattiti intorno allo zero), le osservazioni Y sarebbero state interamente spiegate dal trend lineare $\mu + X\beta$ e dal rumore bianco ε. In tale scenario, una semplice regressione lineare sarebbe stata sufficiente. Al contrario, la significatività di $W(s)$ conferma che la dipendenza spaziale è una componente imprescindibile del fenomeno fisico in esame.

Tuttavia, è necessario fare una distinzione interpretativa. Sebbene la mappa di $W(s)$ permetta di localizzare i cluster (le aree in cui i punti hanno lo stesso colore, quindi valori simili), essa offre una visione statica e puntuale. Per comprendere la dinamica con cui l'influenza si propaga nello spazio — ovvero per quantificare "quanto" e "fino a dove" un punto influenzi i suoi vicini — lo strumento d'elezione rimane la funzione di covarianza $C(h)$ analizzata nella sezione precedente, che sintetizza la regola teorica di decadimento della correlazione.

Infine, un confronto diretto tra la mappa dei valori osservati Y e la media a posteriori di $W(s)$ (Figura 11) rivela una sovrapposizione morfologica sorprendente: la distribuzione dei colori e dei pattern spaziali è pressoché identica. Essendo Y modellizzato come somma del trend, di W e dell'errore, questa similitudine indica che il processo latente non agisce come un mero correttivo marginale, ma rappresenta la componente dominante della variabilità osservata (in altre parole è l'addendo principale nella somma che definisce Y). In altri termini, il livello di log(PM10) misurato in una data località è determinato in larga misura proprio dalla struttura di correlazione spaziale locale, confermando la centralità del Processo Gaussiano nella spiegazione del fenomeno.

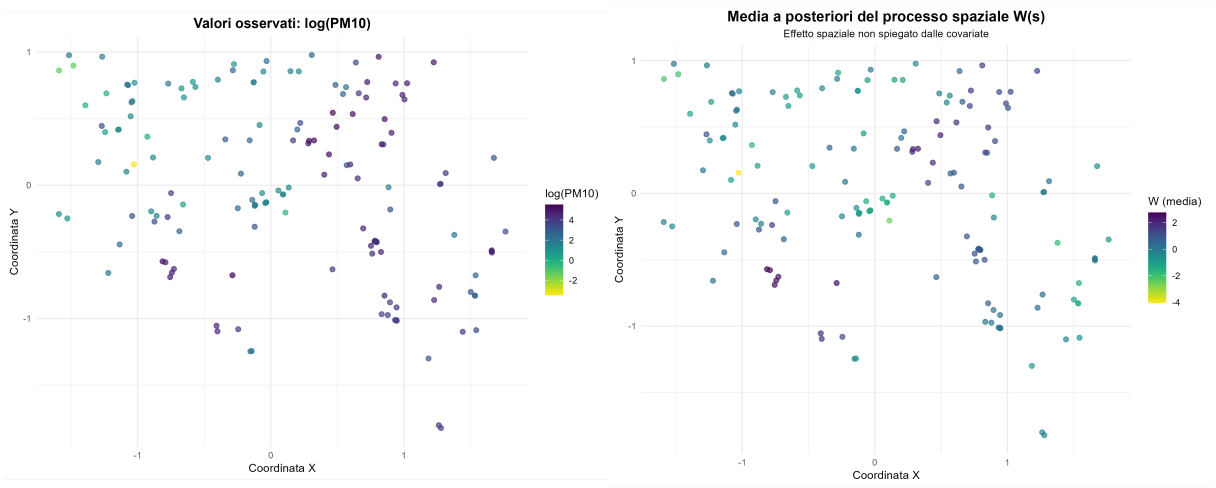


Figura 11: Confronto tra i valori osservati log(PM10) e la media a posteriori del processo spaziale $W(s)$.

4 Predizione Spaziale su Griglia Regolare

Conclusa la stima dei parametri, l'obiettivo finale è la ricostruzione del campo latente $W(\cdot)$ sull'intero dominio spaziale. Definiamo $S = \{s_1, \ldots, s_n\}$ l'insieme dei punti osservati e $A = \{s_{n+1}, \ldots, s_{n+m}\}$ l'insieme dei punti di una griglia regolare su cui vogliamo predire il processo.

4.1 Fondamenti Teorici

Assumendo che $W(\cdot)$ sia un Processo Gaussiano a media nulla con funzione di covarianza $C(\cdot, \cdot; \theta)$ (dove θ include i parametri σ^2 e ϕ), il vettore dei valori del processo su qualunque insieme finito di punti segue una distribuzione normale multivariata. In particolare, definendo i vettori $W_S = (W(s_1), \ldots, W(s_n))^\top$ e $W_A = (W(s_{n+1}), \ldots, W(s_{n+m}))^\top$, la distribuzione congiunta è data da:

$$\begin{pmatrix} W_S \\ W_A \end{pmatrix} \sim N_{n+m}\left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \Sigma(\theta) = \begin{pmatrix} \Sigma_{SS}(\theta) & \Sigma_{SA}(\theta) \\ \Sigma_{AS}(\theta) & \Sigma_{AA}(\theta) \end{pmatrix} \right)$$

dove l'elemento generico $[\Sigma_{UV}(\theta)]_{ij} = C(u_i, v_j; \theta)$. I blocchi della matrice di covarianza si ottengono valutando la funzione C su tutte le coppie di punti in $S \cup A$, sfruttando la proprietà fondamentale per cui la struttura di covarianza del GP è definita sull'intero dominio spaziale continuo.

Per effettuare la predizione sui punti della griglia, si utilizza la distribuzione di W_A condizionata a W_S e ai parametri θ. Grazie alla proprietà di chiusura della normale multivariata, tale distribuzione è ancora gaussiana:

$$W_A \mid W_S, \theta \sim N_m\Big(\mu_{A|S}(\theta),\ \Sigma_{A|S}(\theta)\Big)$$

con media e covarianza condizionate definite come:

$$\mu_{A|S}(\theta) = \Sigma_{AS}(\theta)\, \Sigma_{SS}(\theta)^{-1} W_S$$

$$\Sigma_{A|S}(\theta) = \Sigma_{AA}(\theta) - \Sigma_{AS}(\theta)\, \Sigma_{SS}(\theta)^{-1} \Sigma_{SA}(\theta)$$

4.2 Approssimazione Monte Carlo della Predittiva

Nel contesto bayesiano, i valori osservati del campo latente W_S e i parametri θ sono quantità ignote trattate come variabili aleatorie. Tramite l'algoritmo MCMC, otteniamo un insieme di campioni $\{(W_S^{(b)}, \theta^{(b)})\}_{b=1}^{B}$ dalla distribuzione a posteriori congiunta $p(W_S, \theta \mid Y)$.

Per ogni iterazione b della catena, generiamo quindi un campione predittivo estraendo dalla normale condizionata:

$$W_A^{(b)} \sim p\Big(W_A \mid W_S^{(b)}, \theta^{(b)}\Big) = N_m\Big(\mu_{A|S}(\theta^{(b)}), \Sigma_{A|S}(\theta^{(b)})\Big)$$

Questo procedimento operativo realizza una realizzazione Monte Carlo dalla distribuzione predittiva a posteriori marginale, vediamo come.

Formalmente, per la legge delle probabilità totali, la distribuzione predittiva a posteriori del processo latente nei nuovi punti della griglia può essere scritta come

$$p(W_A \mid Y) = \int p(W_A \mid W_S, \theta, Y)\, p(W_S, \theta \mid Y)\, dW_S\, d\theta.$$

Nel modello gerarchico considerato, le osservazioni Y dipendono dal processo spaziale latente esclusivamente attraverso i valori W_S nei punti osservati, mentre i valori del processo nei nuovi punti W_A sono collegati a W_S unicamente tramite la struttura di correlazione del Processo Gaussiano. Di conseguenza, una volta condizionato rispetto a W_S e ai parametri θ, le nuove componenti del processo risultano condizionalmente indipendenti dalle osservazioni[4] , ovvero

$$p(W_A \mid W_S, \theta, Y) = p(W_A \mid W_S, \theta).$$

Sfruttando tale indipendenza condizionale, la predittiva a posteriori si riduce quindi a

$$p(W_A \mid Y) = \int p(W_A \mid W_S, \theta)\, p(W_S, \theta \mid Y)\, dW_S\, d\theta,$$

L'algoritmo sopra descritto approssima numericamente tale integrale, effettuando una "marginalizzazione" rispetto a W_S e θ tramite i campioni MCMC. Di conseguenza, l'insieme risultante $\{W_A^{(b)}\}_{b=1}^{B}$ approssima la distribuzione target $p(W_A \mid Y)$ e consente, per ciascun punto della griglia, di stimare puntualmente la media a posteriori e di costruire intervalli di credibilità validi, propagando correttamente l'incertezza sia sul campo latente che sui parametri del modello.

[4] La struttura di dipendenza del modello può essere rappresentata dal seguente DAG:

$$W_A \longleftarrow (W_S, \theta) \longrightarrow Y,$$

da cui segue che W_A e Y sono condizionalmente indipendenti dato (W_S, θ).

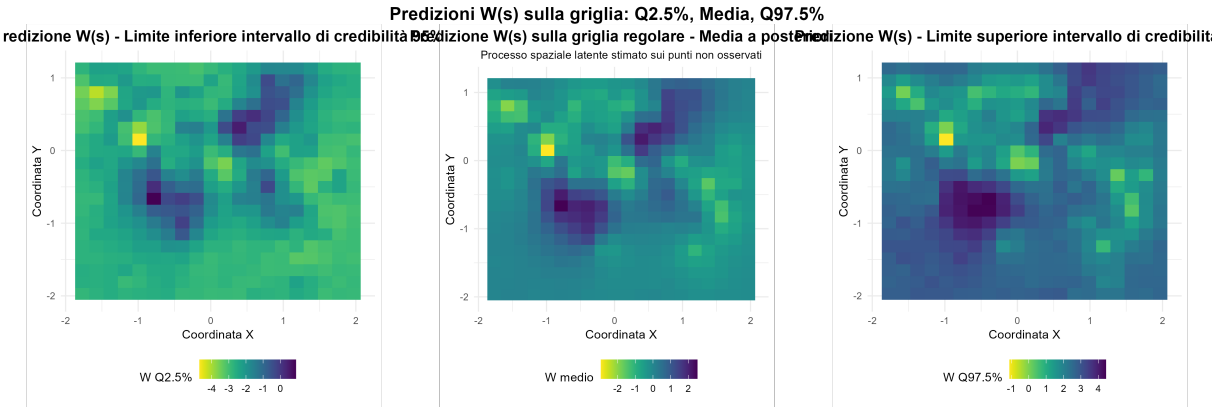


Figura 12: Predizioni del processo latente $W(s)$ sulla griglia regolare: Quantile 2.5%, Media e Quantile 97.5%.

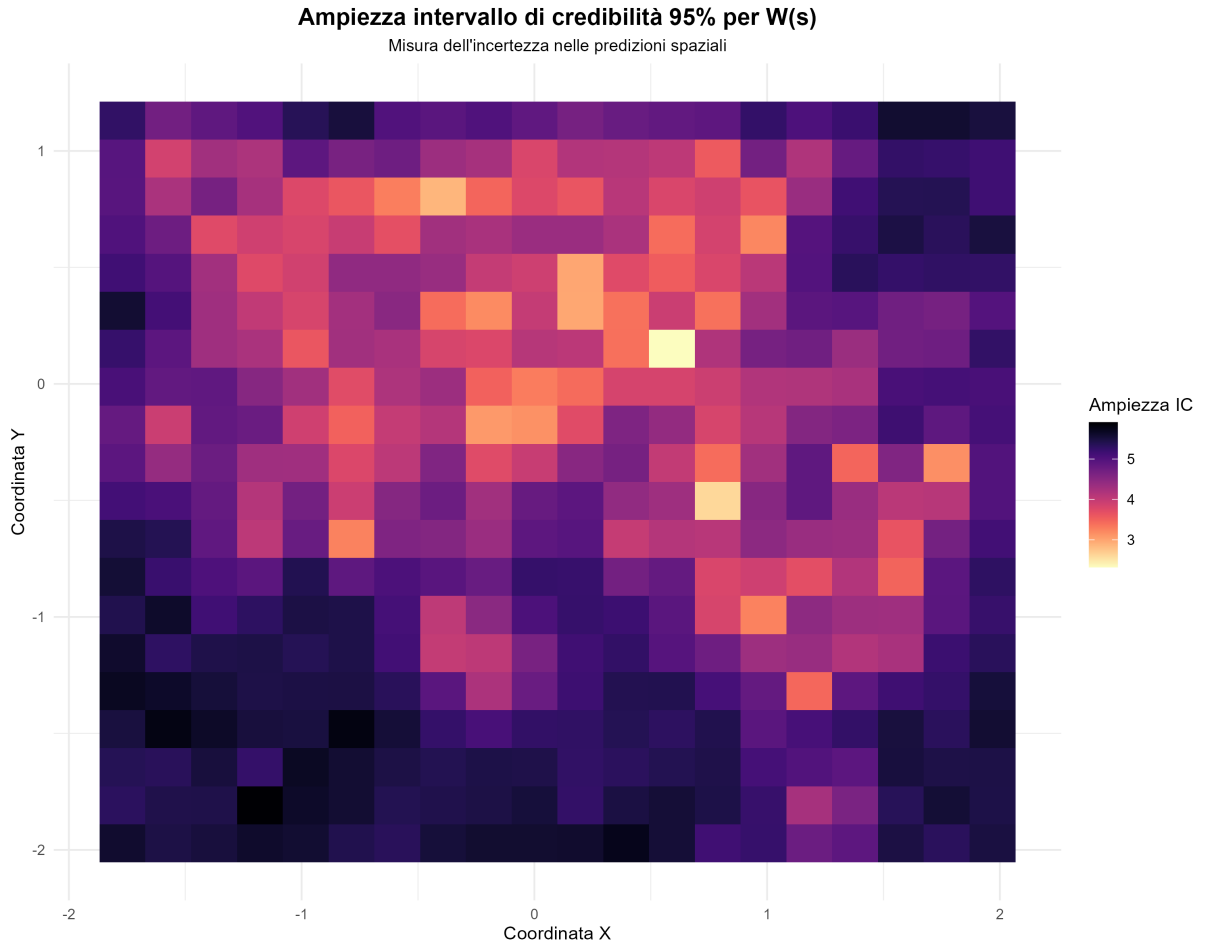


Figura 13: Ampiezza dell'intervallo di credibilità al 95% per $W(s)$, misura dell'incertezza nelle predizioni spaziali.

5 Modello Alternativo: Marginalizzazione rispetto al Processo Latente W

In questa sezione, analizziamo l'approccio alternativo alla stima del modello. Invece di campionare il processo latente W all'interno del Gibbs Sampler (aumentando la dimensione dello spazio dei parametri di n unità), è possibile marginalizzare analiticamente la distribuzione a posteriori rispetto a W. L'obiettivo è ottenere la distribuzione a posteriori marginale dei soli parametri $\theta = (\beta, \sigma^2, \tau^2, \phi)$:

$$\begin{aligned} f(\beta, \sigma^2, \tau^2, \phi \mid y) &= \int_{\mathbb{R}^n} f(\beta, \sigma^2, \tau^2, \phi, W \mid y)\, dW \propto \\ &\propto \int_{\mathbb{R}^n} f(\beta, \sigma^2, \tau^2, \phi, W \mid y) f(W \mid \phi, \sigma^2)\, dW f(\beta) f(\sigma^2) f(\tau^2) f(\phi) \end{aligned}$$

dove abbiamo sfruttato che le altre priors non dipendono da W e quindi escono dall'integrale. L'obiettivo diventa quindi calcolare questo integrale:

$$\int_{\mathbb{R}^n} f(y \mid W, \beta, \tau^2) f(W \mid \phi, \sigma^2)\, dW$$

5.1 Espansione del Nucleo e Completamento del Quadrato

Partiamo dalle densità note:

- Verosimiglianza: $f(y \mid W, \dots) \propto \exp\left(-\frac{1}{2\tau^2}(y - X\beta - W)^T(y - X\beta - W)\right)$
- Prior Spaziale: $f(W \mid \dots) \propto \exp\left(-\frac{1}{2}W^T\Sigma_w^{-1}W\right)$

Il prodotto delle due densità all'interno dell'integrale è:

$$\propto \exp\left(-\frac{1}{2\tau^2}(y - X\beta - W)^T(y - X\beta - W) - \frac{1}{2}W^T\Sigma_w^{-1}W\right)$$

Sviluppiamo il termine quadratico della verosimiglianza ponendo $v = (y - X\beta)$:

$$(v - W)^T(v - W) = v^Tv - v^TW - W^Tv + W^TW = v^Tv - 2v^TW + W^TW$$

Sostituendo nell'esponenziale e raccogliendo i termini rispetto a W:

$$\exp\left(-\frac{1}{2\tau^2}v^Tv + \frac{1}{\tau^2}v^TW - \frac{1}{2\tau^2}W^TW - \frac{1}{2}W^T\Sigma_w^{-1}W\right)$$

Possiamo separare i termini che non dipendono da W (che chiameremo A, costanti rispetto all'integrazione) dai termini in W:

$$= \underbrace{\exp\left(-\frac{1}{2\tau^2}(y - X\beta)^T(y - X\beta)\right)}_{A} \cdot \exp\left(-\frac{1}{2}\left[W^T(\Sigma_w^{-1} + \tau^{-2}I_n)W - 2\tau^{-2}(y - X\beta)^TW\right]\right)$$

Riconosciamo nell'argomento dell'esponenziale il kernel di una Normale Multivariata $N_n(\mu^*, V^*)$. Identifichiamo la matrice di covarianza V^* e il vettore media μ^*:

$$V^* = (\Sigma_w^{-1} + \tau^{-2}I_n)^{-1}$$

$$\mu^* = V^*(\tau^{-2}(y - X\beta))$$

Per risolvere l'integrale, utilizziamo la tecnica del completamento del quadrato matriciale. Aggiungendo e sottraendo il termine quadratico $\frac{1}{2}(\mu^*)^T(V^*)^{-1}\mu^*$, possiamo riscrivere l'esponenziale come:

$$\exp\left(-\frac{1}{2}(W-\mu^*)^T(V^*)^{-1}(W-\mu^*)\right)\cdot\exp\left(\frac{1}{2}(\mu^*)^T(V^*)^{-1}\mu^*\right)$$

Quindi l'integrale di interesse diventa:

$$I = A\cdot\exp\left(\frac{1}{2}(\mu^*)^T(V^*)^{-1}\mu^*\right)\cdot\int_{\mathbb{R}^n}\exp\left(-\frac{1}{2}(W-\mu^*)^T(V^*)^{-1}(W-\mu^*)\right)dW$$

5.2 Risoluzione dell'Integrale tramite Decomposizione Spettrale

Per calcolare rigorosamente l'integrale rimasto, effettuiamo un cambio di variabile. Poniamo $Z = W - \mu^*$, da cui $dZ = dW$:

$$\int_{\mathbb{R}^n}\exp\left(-\frac{1}{2}Z^T(V^*)^{-1}Z\right)dZ$$

La matrice $(V^*)^{-1}$ è simmetrica e definita positiva, quindi ammette una decomposizione spettrale:

$$(V^*)^{-1} = Q\Lambda Q^T$$

dove Q è una matrice ortogonale ($Q^TQ = I$) e $\Lambda = \mathrm{diag}(\lambda_1,\ldots,\lambda_n)$ contiene gli autovalori positivi. Sostituendo nell'integrale:

$$\int_{\mathbb{R}^n}\exp\left(-\frac{1}{2}Z^TQ\Lambda Q^TZ\right)dZ$$

Effettuiamo un ulteriore cambio di variabile $U = Q^TZ$. Poiché $Z = QU$, lo Jacobiano della trasformazione è $J = Q$. Essendo Q ortogonale, $|\det(Q)| = 1$, quindi $dZ = dU$. L'integrale diventa:

$$\int_{\mathbb{R}^n}\exp\left(-\frac{1}{2}U^T\Lambda U\right)dU = \int_{\mathbb{R}^n}\exp\left(-\frac{1}{2}\sum_{i=1}^n\lambda_iu_i^2\right)dU$$

L'integrale multivariato si fattorizza nel prodotto di n integrali univariati gaussiani noti:

$$= \prod_{i=1}^n\int_{-\infty}^{+\infty}\exp\left(-\frac{1}{2}\lambda_iu_i^2\right)du_i = \prod_{i=1}^n\sqrt{\frac{2\pi}{\lambda_i}} = (2\pi)^{n/2}\prod_{i=1}^n\lambda_i^{-1/2}$$

Ricordando che il determinante è il prodotto degli autovalori, abbiamo $\prod\lambda_i = \det((V^*)^{-1}) = \det(V^*)^{-1}$. Pertanto il valore dell'integrale è:

$$(2\pi)^{n/2}|V^*|^{1/2}$$

5.3 Ricomposizione e Semplificazione Algebrica

Sostituendo il risultato dell'integrale nell'espressione I derivata al punto 5.1 e recuperando il termine A:

$$f(y \mid \dots) \propto \exp\left(-\frac{1}{2\tau^2}(y - X\beta)^T(y - X\beta)\right) \exp\left(\frac{1}{2}(\mu^*)^T(V^*)^{-1}\mu^*\right) (2\pi)^{n/2}|V^*|^{1/2}$$

Per semplificare l'espressione, definiamo $v = (y - X\beta)$. Sviluppiamo il termine nell'esponenziale contenente μ^*, ricordando che $\mu^* = V^*(\tau^{-2}v)$ e $V^{*T} = V^*$:

$$\begin{aligned}(\mu^*)^T(V^*)^{-1}\mu^* &= (\tau^{-2}V^*v)^T(V^*)^{-1}(V^*\tau^{-2}v) \\ &= \tau^{-4}v^T(V^*)^T(V^*)^{-1}V^*v = \tau^{-4}v^TV^*v\end{aligned}$$

Ora uniamo questo termine con il termine A:

$$\exp\left(-\frac{1}{2}\left[\tau^{-2}K^TK - \tau^{-4}K^TV^*K\right]\right) = \exp\left(-\frac{1}{2}K^T\left[\tau^{-2}I_n - \tau^{-4}V^*\right]K\right)$$

Analizziamo il termine tra parentesi quadre. Sostituendo $V^* = (\Sigma_w^{-1} + \tau^{-2}I)^{-1}$, è possibile dimostrare che [5]:

$$\tau^{-2}I_n - \tau^{-4}(\Sigma_w^{-1} + \tau^{-2}I)^{-1} = (\Sigma_w + \tau^2 I_n)^{-1}$$

Analogamente, manipolando il termine del determinante $|V^*|^{1/2} = |(\Sigma_w^{-1} + \tau^{-2}I)^{-1}|^{1/2} = |\Sigma_w + \tau^2 I_n|^{-1/2}$ [6]

5.4 Risultato Finale: La Posteriori Marginalizzata

Ricostruendo tutti i pezzi, l'integrale di marginalizzazione rispetto a W porta a:

$$\int f(y \mid W, \dots)f(W \mid \dots)dW \propto |\Sigma_w + \tau^2 I_n|^{-1/2} \exp\left(-\frac{1}{2}(y - X\beta)^T(\Sigma_w + \tau^2 I_n)^{-1}(y - X\beta)\right)$$

Riconosciamo esattamente la densità di una Normale Multivariata marginale:

$$y \mid \beta, \sigma^2, \tau^2, \phi \sim N_n(X\beta,\, \Sigma_w + \tau^2 I_n)$$

Questo risultato conferma che marginalizzare il processo latente W equivale a considerare un modello in cui le osservazioni y hanno una struttura di covarianza marginale data dalla somma della covarianza spaziale e del nugget. La distribuzione a posteriori marginalizzata su cui effettuare MCMC è dunque:

$$f(\beta, \sigma^2, \tau^2, \phi \mid y) \propto N_n(y \mid X\beta, \Sigma_w + \tau^2 I) \cdot f(\beta)f(\sigma^2)f(\tau^2)f(\phi)$$

[5] Per trovare l'ugualianza che segue è stata usata la seguente idea intuitiva. Marginalizzare rispetto al processo latente W equivale a far collassare la gerarchia: y diviene somma diretta di un trend, del processo spaziale e dell'errore. Poiché W ed ϵ sono indipendenti e gaussiani, la varianza marginale di y deve necessariamente essere la somma delle loro varianze, ovvero $\Sigma_w + \tau^2 I_n$. La conferma analitica di questa intuizione si ottiene verificando che il prodotto tra il termine derivato dai calcoli e l'inversa ipotizzata restituisca l'identità. Calcolando $(\tau^{-2}I_n - \tau^{-4}V^*)(\Sigma_w + \tau^2 I_n)$ e sostituendo la definizione $V^* = (\Sigma_w^{-1} + \tau^{-2}I_n)^{-1}$, si osserva attraverso semplici manipolazioni algebriche che i termini misti si elidono perfettamente, restituendo la matrice identità I_n.

[6] La proporzionalità tra $|V^*|^{1/2}$ e $|\Sigma_w + \tau^2 I_n|^{-1/2}$ è dimostrata esplicitamente manipolando l'espressione dell'inversa. Partendo da $V^{*-1} = \Sigma_w^{-1} + \tau^{-2}I_n$, fattorizziamo inizialmente Σ_w^{-1}, ottenendo il determinante di un prodotto: $|\Sigma_w^{-1}(I_n + \tau^{-2}\Sigma_w)|$. Successivamente, all'interno della parentesi, raccogliamo lo scalare τ^{-2}, sfruttando la proprietà fondamentale dei determinanti $|kA| = k^n|A|$. L'espressione diviene quindi $|\Sigma_w^{-1}| \cdot (\tau^{-2})^n \cdot |\tau^2 I_n + \Sigma_w|$. I primi due termini sono assorbiti nella costante di normalizzazione (dato che lavoriamo con il proporsionale di densità), e ricordando che $|V^*|^{1/2} = (|V^{*-1}|)^{-1/2}$, otteniamo infine il termine $|\Sigma_w + \tau^2 I_n|^{-1/2}$ che caratterizza la densità marginale.

5.5 Derivazione delle Full Conditional nel Modello Marginalizzato

In questa sezione deriviamo le full conditional dei parametri β, τ^2, σ^2 e ϕ, che verranno utilizzate all'interno dell'algoritmo MCMC sul modello marginalizzato.

5.5.1 Full Conditional di β

Isoliamo dalla densità a posteriori marginalizzata tutti i termini che dipendono da β:

$$f(\beta \mid \dots) \propto f(y \mid \beta, \sigma^2, \tau^2, \phi)\, f(\beta),$$

poiché le altre priors non coinvolgono β. Ricordiamo che:

$$y \mid \cdots \sim N_n(X\beta, \Sigma_y), \qquad \beta \sim N_3(0, 10^4 I_3).$$

Scrivendo esplicitamente i kernel delle densità:

$$f(\beta \mid \dots) \propto |\Sigma_y|^{-1/2} \exp\left(-\frac{1}{2}(y - X\beta)^T \Sigma_y^{-1}(y - X\beta)\right) \exp\left(-\frac{1}{2}\beta^T B^{-1}\beta\right),$$

dove $B = 10^4 I_3$.

Espandiamo il termine quadratico della verosimiglianza:

$$\begin{aligned}(y - X\beta)^T \Sigma_y^{-1}(y - X\beta) = {} & y^T\Sigma_y^{-1}y - y^T\Sigma_y^{-1}X\beta \\ & - \beta^T X^T\Sigma_y^{-1}y + \beta^T X^T\Sigma_y^{-1}X\beta.\end{aligned}$$

Poiché l'espressione è uno scalare e Σ_y^{-1} è simmetrica, i due termini centrali coincidono, e possiamo riscrivere:

$$= y^T\Sigma_y^{-1}y - 2\beta^T X^T\Sigma_y^{-1}y + \beta^T X^T\Sigma_y^{-1}X\beta.$$

Rimuovendo i termini indipendenti da β e combinando con la prior, otteniamo:

$$f(\beta \mid \dots) \propto \exp\left[-\frac{1}{2}\left(\beta^T\left(X^T\Sigma_y^{-1}X + \frac{1}{10^4}I_3\right)\beta - 2\beta^T X^T\Sigma_y^{-1}y\right)\right].$$

Riconosciamo il kernel di una normale multivariata, con:

$$V = \left(X^T\Sigma_y^{-1}X + \frac{1}{10^4}I_3\right)^{-1}, \qquad \mu = VX^T\Sigma_y^{-1}y.$$

Pertanto:

$$\beta \mid \cdots \sim N_3(\mu, V).$$

5.5.2 Full Conditional di τ^2

La full conditional di τ^2 è proporzionale al prodotto tra la verosimiglianza marginale e la prior:

$$f(\tau^2 \mid \dots) \propto f(y \mid \beta, \sigma^2, \tau^2, \phi)\, f(\tau^2).$$

Definiamo il residuo $r = y - X\beta \in \mathbb{R}^n$. La verosimiglianza è:

$$f(y \mid \dots) = (2\pi)^{-n/2}|\Sigma_y|^{-1/2} \exp\left(-\frac{1}{2}r^T\Sigma_y^{-1}r\right),$$

mentre la prior è:

$$\tau^2 \sim IG(1,1) \quad \Rightarrow \quad f(\tau^2) \propto (\tau^2)^{-2} \exp\left(-\frac{1}{\tau^2}\right).$$

Trascurando i termini che non dipendono da τ^2, otteniamo:

$$f(\tau^2 \mid \dots) \propto |\Sigma_y|^{-1/2} \exp\left(-\frac{1}{2} r^T \Sigma_y^{-1} r - \frac{1}{\tau^2}\right) (\tau^2)^{-2}.$$

Poiché τ^2 compare sia nel determinante che nell'inversa di Σ_y, la full conditional non è riconducibile a una Inverse Gamma in forma chiusa. Di conseguenza, l'aggiornamento di τ^2 viene effettuato tramite un passo Metropolis–Hastings all'interno del Gibbs sampler. La log-densità target risulta:

$$\log f(\tau^2 \mid \dots) = -\frac{1}{2} \log |\sigma^2 R_\phi + \tau^2 I_n| - \frac{1}{2} r^T (\sigma^2 R_\phi + \tau^2 I_n)^{-1} r - \frac{1}{\tau^2} - 2\log(\tau^2).$$

5.5.3 Full Conditional di σ^2

Con argomentazioni del tutto analoghe, la full conditional di σ^2 è:

$$f(\sigma^2 \mid \dots) \propto f(y \mid \beta, \sigma^2, \tau^2, \phi)\, f(\sigma^2),$$

con prior $\sigma^2 \sim IG(1,1)$. Si ottiene:

$$f(\sigma^2 \mid \dots) \propto |\Sigma_y|^{-1/2} \exp\left(-\frac{1}{2} r^T \Sigma_y^{-1} r - \frac{1}{\sigma^2}\right) (\sigma^2)^{-2}.$$

Anche in questo caso σ^2 entra sia nel determinante che nell'inversa di Σ_y, rendendo necessario l'uso di Metropolis–Hastings. La log-densità è:

$$\log f(\sigma^2 \mid \dots) = -\frac{1}{2} \log |\sigma^2 R_\phi + \tau^2 I_n| - \frac{1}{2} r^T (\sigma^2 R_\phi + \tau^2 I_n)^{-1} r - \frac{1}{\sigma^2} - 2\log(\sigma^2).$$

5.5.4 Full Conditional di ϕ

Infine, la full conditional del parametro di decadimento spaziale ϕ è data da:

$$f(\phi \mid \dots) \propto f(y \mid \beta, \sigma^2, \tau^2, \phi)\, f(\phi),$$

dove la prior è uniforme su (a, b). Poiché ϕ entra esclusivamente attraverso la matrice di correlazione R_ϕ, otteniamo:

$$f(\phi \mid \dots) \propto |\Sigma_y|^{-1/2} \exp\left(-\frac{1}{2} r^T \Sigma_y^{-1} r\right) \mathbb{I}_{(a,b)}(\phi).$$

Anche questa densità non è riconducibile a una forma nota, per cui l'aggiornamento di ϕ viene effettuato tramite un passo Metropolis–Hastings. La log-densità target risulta:

$$\log f(\phi \mid \dots) = -\frac{1}{2} \log |\sigma^2 R_\phi + \tau^2 I_n| - \frac{1}{2} r^T (\sigma^2 R_\phi + \tau^2 I_n)^{-1} r, \qquad \phi \in (a, b).$$

5.6 Note Implementative e Analisi dei Risultati

Dal punto di vista implementativo, la marginalizzazione del processo latente W comporta (come già anticipato) la perdita della coniugatezza per i parametri di varianza τ^2 e σ^2.

Per campionare efficacemente tali parametri e ϕ tramite Metropolis-Hastings, abbiamo adottato la strategia analoga a quanto fatto per il parametro ϕ (Sezione 2.4) per ciascuno dei tre parametri τ^2, σ^2 e ϕ. Anziché proporre nuovi valori sulla scala originale, la proposta avviene sul logaritmo del parametro:

$$\log(\theta^*) \sim N(\log(\theta^{(t-1)}), \eta^2) \quad \text{per } \theta \in \{\tau^2, \sigma^2\, \phi\}$$

Questa scelta implementativa richiede una particolare attenzione teorica nel calcolo del rapporto di accettazione. Poiché la catena opera nello spazio trasformato dei logaritmi ($\psi = \log\theta$), mentre la distribuzione target è definita sullo spazio originale dei parametri positivi, è necessario applicare la formula del cambio di variabile per le densità di probabilità come visto precedentemente per ϕ nella Sezione 2.4, ottenendo:

$$\log f_{\text{target}}(\theta^*) + \log(\theta^*)$$

Senza questo termine correttivo, derivante dalla distorsione geometrica indotta dalla scala logaritmica, l'algoritmo non convergerebbe alla corretta distribuzione stazionaria.

Grazie a questa accortezza e all'adattamento della varianza della proposta, i tassi di accettazione si sono stabilizzati su valori ottimali: 41.27% per τ^2, 22.31% per σ^2 e 25.84% per ϕ, indicando un eccellente bilanciamento tra esplorazione globale e campionamento locale.

Riportiamo di seguito (Tabella 3) le stime a posteriori ottenute con il modello marginalizzato.

Tabella 3: Stime a posteriori del modello marginalizzato

Parametro	**Media Post.**	**Dev. Std.**	**IC 2.5%**	**IC 97.5%**
Trend				
μ	2.7246	0.3724	1.9573	3.4544
β_1	0.8802	0.3393	0.2176	1.5480
β_2	-0.2957	0.4337	-1.0904	0.5706
Varianza e Spazio				
τ^2	0.2432	0.0902	0.1123	0.4533
σ^2	1.9418	0.6672	1.1756	3.5936
ϕ	3.5939	1.2552	1.3221	6.3183

Confrontando questi risultati con quelli ottenuti dal modello gerarchico completo (Tabella 2), emerge una **sostanziale sovrapposizione delle stime**. Le medie a posteriori sono quasi identiche (es. $\beta_1 \approx 0.88$ in entrambi i casi, $\sigma^2 \approx 1.94$ contro 1.96) e gli intervalli di credibilità confermano le stesse conclusioni inferenziali.

Il modello marginalizzato conferma dunque la robustezza dell'inferenza condotta: sebbene i due algoritmi operino su spazi di parametri di dimensione drasticamente diversa (il primo include le n variabili latenti W, il secondo le integra analiticamente), essi convergono alla medesima distribuzione a posteriori marginale per i parametri strutturali.

Esercizio 2

6 Analisi esplorativa delle traiettorie e motivazione del modello HMM

Prima di procedere alla formalizzazione del modello bayesiano, abbiamo condotto un'analisi esplorativa sui dati grezzi per comprendere la struttura spaziale e temporale del movimento del cane. L'obiettivo di questa fase preliminare è verificare se le ipotesi alla base di un modello Hidden Markov (HMM) trovino riscontro nell'evidenza empirica. Abbiamo innanzitutto ricostruito la traiettoria spaziale nel piano 2D (Figura 14). Per arricchire la visualizzazione, ogni punto è stato colorato in base a un indice di "tempo di permanenza", calcolato su una soglia di spostamento di 0.15 unità.

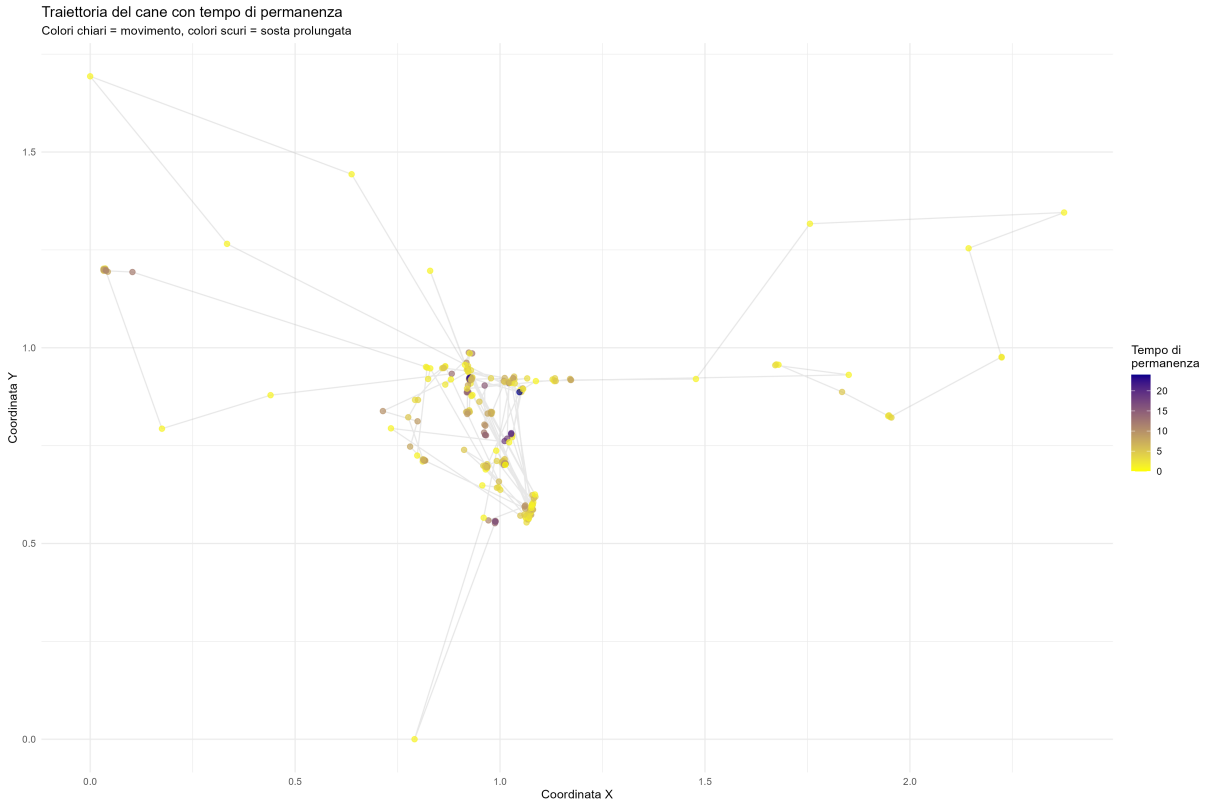


Figura 14: Traiettoria del cane con tempo di permanenza. Colori chiari = movimento, colori scuri = sosta prolungata.

La scelta di tale soglia non è arbitraria, ma deriva dall'analisi della distribuzione empirica delle distanze percorse passo-passo (Figura 15). L'istogramma evidenzia un andamento chiaramente multimodale: osserviamo un primo picco centrato sullo zero, associabile a uno stato di inattività o micro-movimenti, e una seconda moda attorno a 0.25, indicativa di uno stato di attività e spostamento effettivo. Il valore 0.15 si colloca nella "valle" che separa queste due campane, fungendo da naturale punto di taglio per discriminare tra stasi e movimento.

Tornando alla mappa, emerge chiaramente una macro-area centrale ad alta densità. Tuttavia, osservando con maggiore attenzione la distribuzione dei punti scuri (alta permanenza) all'interno di questo nucleo, notiamo che non si tratta di una massa uniforme:

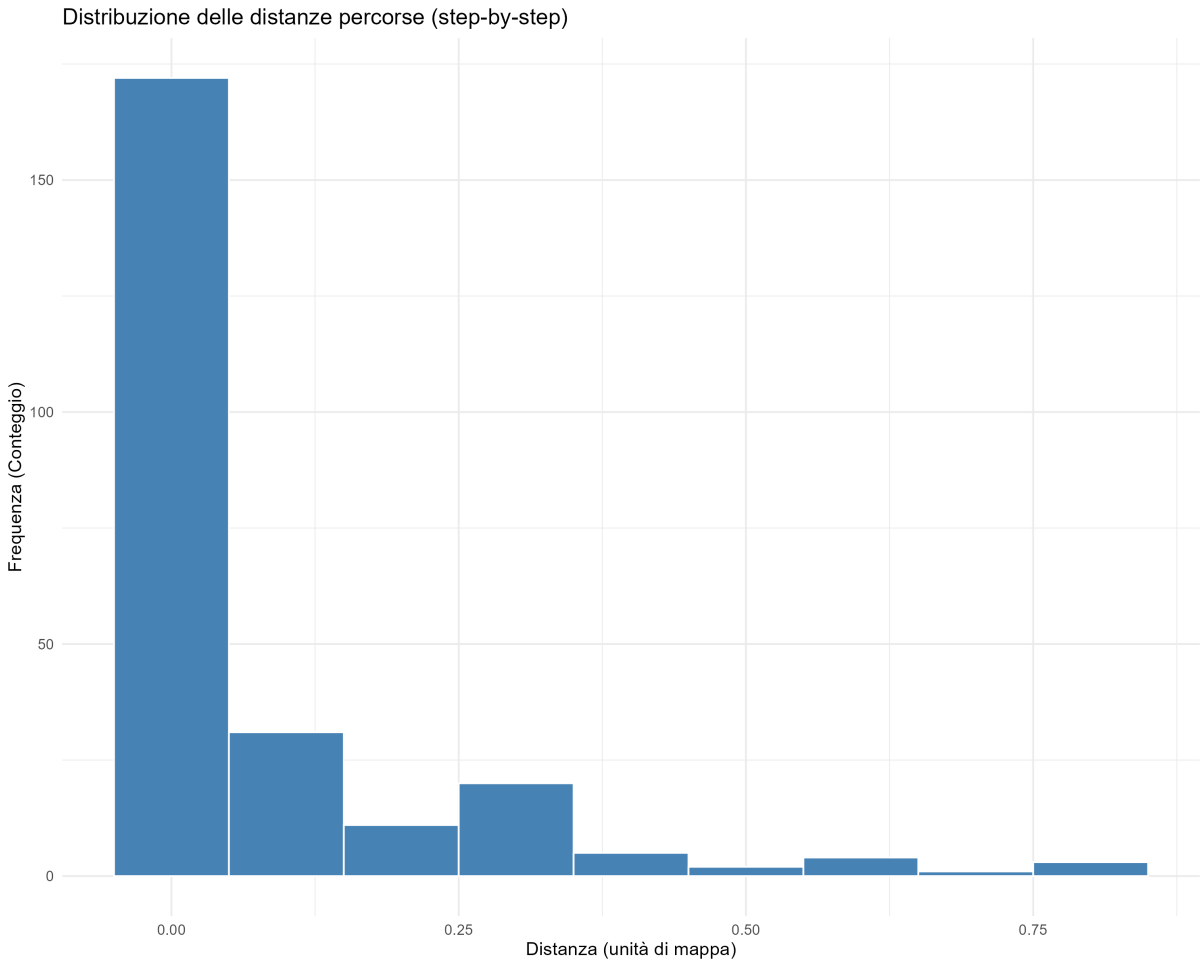


Figura 15: Distribuzione delle distanze percorse (step-by-step).

si distinguono invece specifici punti di concentrazione o "sotto-cluster". Queste aree potrebbero rappresentare diverse zone di interesse o di presidio (es. "Zona di presidio A", "Zona di presidio B") all'interno del territorio abituale del cane. Questa eterogeneità spaziale suggerisce che le variabili latenti del modello non dovrebbero limitarsi a distinguere genericamente "dentro/fuori", ma potrebbero catturare strutture spaziali più complesse. La giustificazione più forte per l'adozione di un HMM emerge però dal confronto incrociato delle serie storiche delle coordinate (Figura 16). È proprio dall'analisi congiunta dei grafici di X e Y che notiamo una marcata sincronia: i lunghi intervalli in cui la coordinata X rimane costante coincidono perfettamente con i periodi di stasi della coordinata Y. Questo conferma che se il cane è fermo in una certa posizione al tempo t, vi è un'elevata probabilità che vi rimanga anche al tempo $t + 1$.

Alla luce delle evidenze emerse, l'adozione di un modello mistura a osservazioni indipendenti risulterebbe inadeguata. La forte dipendenza temporale e la struttura spaziale osservata giustificano l'introduzione formale di un Hidden Markov Model (HMM). In questo contesto, l'inserimento delle variabili latenti z_i rappresenta un costrutto matematico necessario a priori per catturare la "memoria" del processo e la sua multimodalità. Sarà poi l'analisi a posteriori delle stime ottenute a permetterci di attribuire un significato concreto a tali stati, verificando se essi corrispondano effettivamente a specifiche zone funzionali di presidio o se discriminino tra distinti regimi cinetici (stasi vs movimento).

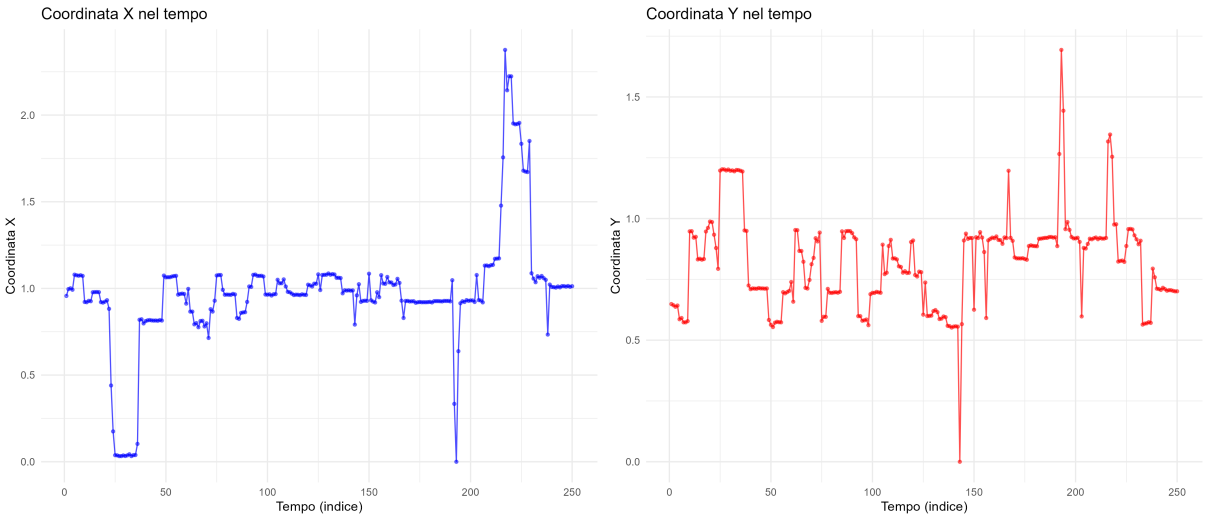


Figura 16: Coordinata X e Coordinata Y nel tempo.

7 Derivazione delle Full Conditional

In questa sezione riportiamo i calcoli dettagliati per la derivazione delle distribuzioni condizionate complete (full conditionals) necessarie per l'implementazione del Gibbs Sampler.

7.1 Full Conditional per le medie μ_k

La full conditional per il vettore delle medie μ_k si ottiene combinando la prior gaussiana con la verosimiglianza ristretta ai soli dati appartenenti allo stato k. Definendo l'insieme degli indici associati allo stato k come $I_k = \{i : z_i = k\}$, la densità a posteriori risulta proporzionale a:

$$f(\mu_k \mid \dots) \propto \exp\left\{-\frac{1}{2}\mu_k^T \left(\frac{1}{100}I\right)\mu_k\right\} \cdot \prod_{i \in I_k} \exp\left\{-\frac{1}{2}(y_i - \mu_k)^T \Sigma_k^{-1}(y_i - \mu_k)\right\}$$

Procediamo espandendo il termine quadratico all'interno dell'esponente della verosimiglianza:

$$(y_i - \mu_k)^T \Sigma_k^{-1}(y_i - \mu_k) = y_i^T \Sigma_k^{-1} y_i - y_i^T \Sigma_k^{-1}\mu_k - \mu_k^T \Sigma_k^{-1} y_i + \mu_k^T \Sigma_k^{-1}\mu_k$$

Analizzando i termini, osserviamo che $y_i^T \Sigma_k^{-1} y_i$ può essere assorbito nella costante di proporzionalità in quanto non dipende da μ_k. Inoltre, essendo ogni addendo uno scalare, vale la proprietà di simmetria per cui $-\mu_k^T \Sigma_k^{-1} y_i = -y_i^T \Sigma_k^{-1}\mu_k$; di conseguenza i termini misti si sommano, risultando in $-2\mu_k^T \Sigma_k^{-1} y_i$.

Sostituendo queste espressioni e sommando su tutti gli $i \in I_k$, l'esponente totale diventa:

$$-\frac{1}{2}\left[\mu_k^T \left(\frac{1}{100}I\right)\mu_k + \sum_{i \in I_k}(\mu_k^T \Sigma_k^{-1}\mu_k - 2\mu_k^T \Sigma_k^{-1} y_i)\right]$$

Definendo $n_k = |I_k|$ come la cardinalità dell'insieme (il numero di osservazioni nello stato k), possiamo raccogliere i termini rispetto a μ_k:

$$-\frac{1}{2}\left[\mu_k^T \left(n_k \Sigma_k^{-1} + \frac{1}{100}I\right)\mu_k - 2\mu_k^T \Sigma_k^{-1} \sum_{i \in I_k} y_i\right]$$

Riconosciamo in questa espressione il kernel di una distribuzione Normale Multivariata. Pertanto, la full conditional è $\mu_k \sim N(\mu^*, V)$ con parametri dati da:

$$V^{-1} = n_k \Sigma_k^{-1} + \frac{1}{100} I$$

$$\mu^* = V \left(\Sigma_k^{-1} \sum_{i \in I_k} y_i \right)$$

7.2 Full Conditional per le matrici di covarianza Σ_k

Per la matrice di covarianza, partiamo dalla prior coniugata Inverse-Wishart $IW(4, I)$ e la moltiplichiamo per la verosimiglianza:

$$f(\Sigma_k \mid \dots) \propto |\Sigma_k|^{-\frac{7}{2}} e^{-\frac{1}{2}\mathrm{tr}(\Sigma_k^{-1})} \cdot |\Sigma_k|^{-\frac{n_k}{2}} \exp\left\{ -\frac{1}{2} \sum_{i \in I_k} (y_i - \mu_k)^T \Sigma_k^{-1} (y_i - \mu_k) \right\}$$

[7] Per manipolare agevolmente l'esponente della verosimiglianza, definiamo il residuo $x = y_i - \mu_k$. Notiamo che il termine $x^T \Sigma_k^{-1} x$ è uno scalare, e quindi coincide con la sua traccia: $x^T \Sigma_k^{-1} x = \mathrm{tr}(x^T \Sigma_k^{-1} x)$. Sfruttando la proprietà ciclica della traccia, per cui $\mathrm{tr}(YZ) = \mathrm{tr}(ZY)$, e ponendo $Y = x^T$ e $Z = \Sigma_k^{-1} x$, otteniamo:

$$\mathrm{tr}(x^T \Sigma_k^{-1} x) = \mathrm{tr}(\Sigma_k^{-1} x x^T) = \mathrm{tr}(\Sigma_k^{-1} (y_i - \mu_k)(y_i - \mu_k)^T)$$

Grazie alla linearità della traccia, possiamo portare la sommatoria al suo interno:

$$\sum_{i \in I_k} (y_i - \mu_k)^T \Sigma_k^{-1} (y_i - \mu_k) = \mathrm{tr}\left(\Sigma_k^{-1} \sum_{i \in I_k} (y_i - \mu_k)(y_i - \mu_k)^T \right)$$

Definiamo ora la matrice delle somma dei quadrati degli scarti A_k come:

$$A_k = \sum_{i \in I_k} (y_i - \mu_k)(y_i - \mu_k)^T$$

L'esponente complessivo nella full conditional si riscrive dunque come:

$$-\frac{1}{2} \left[\mathrm{tr}(\Sigma_k^{-1}) + \mathrm{tr}(\Sigma_k^{-1} A_k) \right] = -\frac{1}{2} \mathrm{tr}(\Sigma_k^{-1} (I + A_k))$$

Questa forma funzionale identifica una distribuzione Inverse-Wishart $IW(\nu_{post}, \Psi_{post})$ con i seguenti parametri a posteriori:

$$\nu_{post} = n_k + 4$$

$$\Psi_{post} = I + A_k = I + \sum_{i \in I_k} (y_i - \mu_k)(y_i - \mu_k)^T$$

[7] La produttoria della verosomiglianza è gia stata portata a esponente per il determinante e a sommatoria per l'esponenziale

7.3 Full Conditional per le probabilità di transizione π_k

Consideriamo il caso specifico con $L = 2$ stati. La k-esima riga della matrice di transizione è il vettore $\pi_k = (\pi_{k1}, \pi_{k2})$. Assumendo come prior una Dirichlet simmetrica con parametri unitari, ovvero $\pi_k \sim Dir(1, 1)$, la densità condizionata è:

$$f(\pi_k \mid \dots) \propto \pi_{k1}^{1-1}\pi_{k2}^{1-1} \cdot \prod_{j=1}^{2} \pi_{kj}^{n_{kj}}$$

Dove n_{kj} rappresenta il conteggio delle transizioni osservate dallo stato k allo stato j nella sequenza latente z. Raggruppando i termini otteniamo:

$$f(\pi_k \mid \dots) \propto \pi_{k1}^{n_{k1}}\pi_{k2}^{n_{k2}}$$

Riconosciamo immediatamente il nucleo di una distribuzione Dirichlet aggiornata:

$$\pi_k \mid \dots \sim \text{Dirichlet}(n_{k1} + 1, n_{k2} + 1)$$

7.4 Full Conditional per lo stato iniziale z_0

Infine, per lo stato iniziale z_0, la distribuzione condizionata dipende esclusivamente dalla prior su z_0 e dalla probabilità di transizione verso il primo stato della catena, z_1:

$$f(z_0 = k \mid \dots) \propto f(z_0 = k) f(z_1 \mid z_0 = k, \pi)$$

Sapendo che a priori $P(z_0 = k) = 1/L = 1/2$, valore costante per ogni k, la relazione di proporzionalità si semplifica in:

$$f(z_0 = k \mid \dots) \propto \frac{1}{2}\pi_{k,z_1} \propto \pi_{k,z_1}$$

Normalizzando su tutti i possibili stati k, otteniamo la probabilità discreta:

$$P(z_0 = k \mid \dots) = \frac{\pi_{k,z_1}}{\sum_{j=1}^{2} \pi_{j,z_1}}$$

7.5 Campionamento del vettore latente z (Algoritmo di Viterbi)

Completato l'aggiornamento dei parametri del modello, rimane da campionare il vettore delle variabili latenti $\mathbf{z}$. Per effettuare questa operazione, invece di utilizzare un approccio Gibbs classico — ovvero campionare ogni componente singolarmente dalla sua condizionata completa $f(z_i \mid z_{-i}, \mathbf{y}, \dots)$ — risulta molto più efficiente estrarre un campione direttamente dalla distribuzione congiunta $f(z_{1:n} \mid \mathbf{y}, \Theta, P)$. Questo approccio, noto come algoritmo di Viterbi, permette di campionare l'intero vettore sfruttando la struttura di dipendenza Markoviana.

Questo obiettivo può essere raggiunto sfruttando la regola della catena per fattorizzare la densità a posteriori congiunta nel seguente modo:

$$f(z_{1:n} \mid \mathbf{y}) = f(z_n \mid \mathbf{y}) \cdot f(z_{n-1} \mid z_n, \mathbf{y}) \cdot f(z_{n-2} \mid z_{n-1}, z_n, \mathbf{y}) \cdot \dots \cdot f(z_1 \mid z_{2:n}, \mathbf{y})$$

Questa scomposizione suggerisce una procedura operativa per il campionamento sequenziale a ritroso:

- Campioniamo inizialmente l'ultimo stato: $z_n \sim f(z_n \mid \mathbf{y}, \Theta, P)$;
- Campioniamo il penultimo condizionatamente all'ultimo: $z_{n-1} \sim f(z_{n-1} \mid z_n, \mathbf{y}, \Theta, P)$;
- Procediamo iterativamente fino al primo stato: $z_1 \sim f(z_1 \mid z_{2:n}, \mathbf{y}, \Theta, P)$.

Al termine della procedura, otteniamo un vettore aleatorio $(z_1, \ldots, z_n)$ che rappresenta un campione esatto estratto dalla distribuzione congiunta di interesse $f(z_{1:n} \mid \mathbf{y}, \Theta, P)$.

7.5.1 Fase 1: Calcolo delle variabili Forward (α)

La prima fase consiste nel calcolare ricorsivamente, per ogni istante $i = 1, \ldots, n$ e per ogni possibile stato $k \in \{1, \ldots, L\}$, la quantità $\alpha_i(k)$, definita come la densità congiunta delle osservazioni fino al tempo i e dello stato corrente [8]:

$$\alpha_i(k) = f(y_1, \ldots, y_i, z_i = k \mid \Theta)$$

dove Θ indica l'insieme dei parametri correnti. Nel nostro codice, iniziamo pre-calcolando le densità di emissione $f(y_i \mid z_i = k, \Theta_k)$ per tutti i punti e gli stati, salvandole nella matrice `dens_calcolate`. Poiché le osservazioni sono coordinate spaziali (X, Y), utilizziamo la funzione `dmvnorm` specificando i vettori media e le matrici di covarianza correnti (μ_k, Σ_k) per valutare la Normale Bivariata.

Inizializzazione: Al tempo $t = 1$, la probabilità dipende dallo stato iniziale z_0 (campionato al passo precedente tramite la matrice di transizione P) e dalla verosimiglianza della prima osservazione. Nel codice calcoliamo:

$$\alpha_1(k) = \texttt{dens_calcolate}[1, k] \cdot \pi_{z_0,k}$$

dove $\pi_{z_0,k}$ è la probabilità di transizione estratta dalla riga corrispondente di P.

Ricorsione ($i > 1$): Per gli istanti successivi, calcoliamo $\alpha_i(k)$ sommando su tutti i possibili stati al tempo precedente. Utilizzando l'indice k_{i-1} per indicare lo stato al tempo $i-1$, la relazione ricorsiva è:

$$\alpha_i(k) = f(y_i \mid z_i = k, \Theta_k) \sum_{k_{i-1}=1}^{L} \pi_{k_{i-1},k}\, \alpha_{i-1}(k_{i-1})$$

Nel ciclo `for` implementato nel codice, questo corrisponde a moltiplicare la densità di emissione corrente (`dens_calcolate[t,k]`) per la somma pesata delle `alfa_matrice[t-1, ]`, dove i pesi sono dati dalle probabilità di transizione `P[k_i1, k]`.

Nota sulla Normalizzazione e Stabilità Numerica: Teoricamente, le $\alpha_i(k)$ tendono a decrescere esponenzialmente verso zero, causando problemi di underflow. Per ovviare a ciò, nel codice eseguiamo una normalizzazione ad ogni passo i: dividiamo il vettore `alfa_matrice[t,]` per la sua somma (`sum(alfa_matrice[t,])`), in modo che le probabilità sommino a 1. Questa operazione non altera il successivo campionamento backward, poiché esso dipende solo dai rapporti di proporzionalità tra le probabilità (che non vengono cambiati da una normalizzazione), ma garantisce la stabilità numerica necessaria.

[8] $\alpha_i(k)$ misura quanto è plausibile che lo stato latente z_i sia uguale a k date tutte le osservazioni fino al tempo i

7.5.2 Fase 2: Backward Sampling

Una volta popolata la matrice `alfa_matrice`, procediamo al campionamento della traiettoria a ritroso, partendo da n fino a 1.

- **Campionamento di z_n**: L'ultimo stato viene estratto direttamente dal vettore `alfa_matrice[n,]` normalizzato, che rappresenta la probabilità marginale dello stato finale data tutta la serie osservata.
- **Campionamento di z_i dato z_{i+1}**: Per $i = n-1, \dots, 1$, campioniamo lo stato corrente condizionatamente allo stato futuro z_{i+1} appena generato (nel codice `z_futuro`). La probabilità di scegliere un determinato stato k è data dalla relazione di proporzionalità:
$$P(z_i = k \mid z_{i+1}, \mathbf{y}, \Theta) \propto \alpha_i(k) \cdot \pi_{k,z_{i+1}}$$

Nel codice, costruiamo il vettore dei pesi `prob_t` moltiplicando elemento per elemento il vettore `alfa_matrice[t,]` (l'evidenza passata) con la colonna della matrice di transizione `P[, z_futuro]` (la compatibilità futura). Per l'estrazione utilizziamo la funzione `sample()`. È importante notare una caratteristica fondamentale di questa funzione: essa accetta nel parametro `prob` un vettore di pesi non necessariamente normalizzati. Pertanto, anche se il nostro prodotto $\alpha \cdot \pi$ non somma a 1, la funzione `sample()` provvede internamente alla normalizzazione, restituendo un indice valido nel supporto $\{1, \dots, L\}$. Questo ci evita di dover calcolare manualmente la costante di normalizzazione della probabilità a posteriori ad ogni passo.

8 Discussione dei Risultati e Diagnostica del Modello ($L = 2$)

L'algoritmo MCMC è stato eseguito per un totale di $B = 50.000$ iterazioni. Al fine di garantire l'indipendenza dalla condizione iniziale, le prime 20.000 iterazioni sono state scartate come fase di burn-in, conservando le successive 30.000 per l'inferenza a posteriori. Di seguito presentiamo l'analisi della convergenza e l'interpretazione fisica dei parametri stimati per il modello a 2 stati.

8.1 Diagnostica MCMC: Convergenza e Mixing

La validità dell'inferenza bayesiana condotta è supportata da una diagnostica estremamente solida, come emerge dall'analisi visiva dei traceplot e dalle statistiche di efficienza:

- **Stazionarietà e Mixing:** I traceplot relativi a tutti i parametri del modello (μ, Σ, π) (Figure 17, 18, 19) indicano inequivocabilmente che la catena ha raggiunto la distribuzione stazionaria e sta esplorando lo spazio dei parametri con un ottimo mixing.
- **Assenza di Label Switching:** L'assenza di questo fenomeno è confermata dall'ispezione dei traceplot delle medie μ_k. Questi parametri rimangono perfettamente stabili sui rispettivi livelli, senza mai "incrociarsi" o mescolarsi tra i due stati. Abbiamo focalizzato il controllo sulle medie poiché rappresentano i parametri più distinti e geometricamente separati del modello; di conseguenza, la stabilità osservata su di

esse è condizione sufficiente a garantire l'assenza del fenomeno anche sulle matrici di covarianza e sugli altri parametri, assicurando la piena identificabilità del modello.

- **Efficienza del Campionamento:** L'algoritmo dimostra un'efficienza computazionale notevole. Come riportato in Tabella 1, i valori di Effective Sample Size (ESS) risultano elevati per tutti i blocchi di parametri. Questo risultato conferma che l'adozione dell'algoritmo di Viterbi (Forward-Backward) per il campionamento in blocco del vettore latente $\mathbf{z}$ ha abbattuto drasticamente l'autocorrelazione della catena.

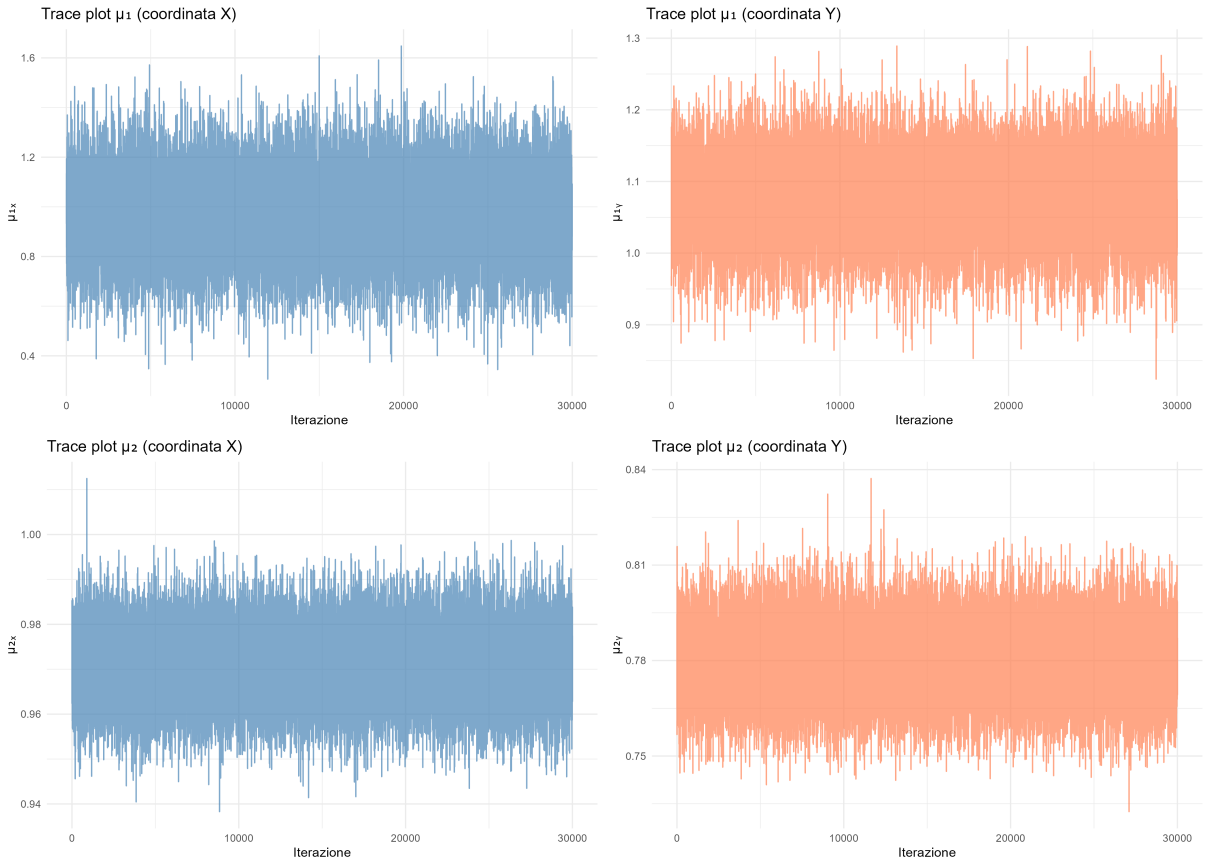


Figura 17: Traceplots dei parametri μ per i due stati.

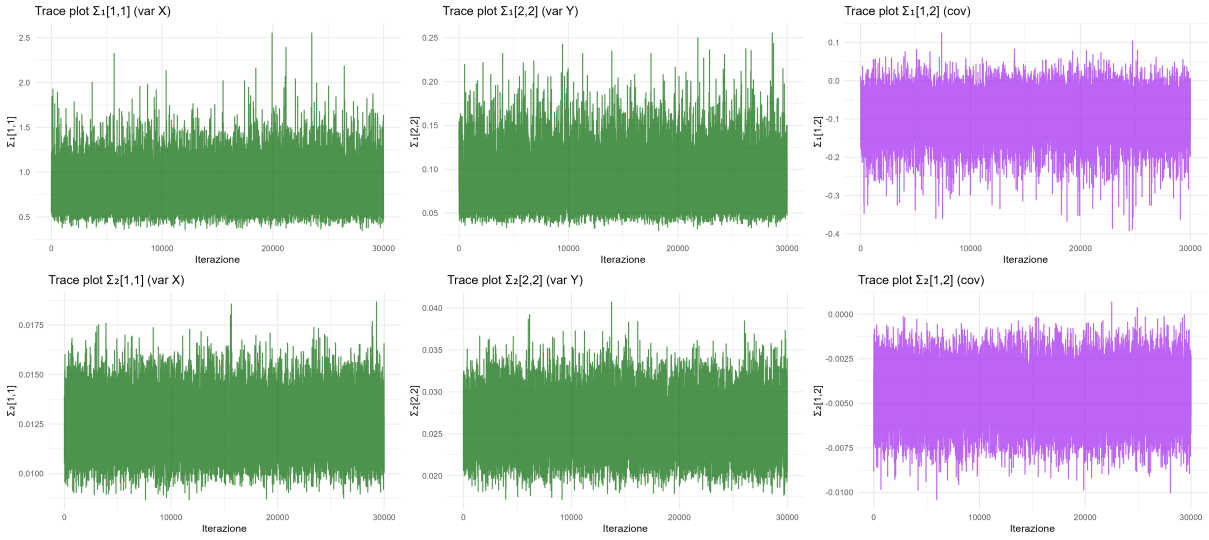


Figura 18: Traceplots dei parametri Σ per i due stati.

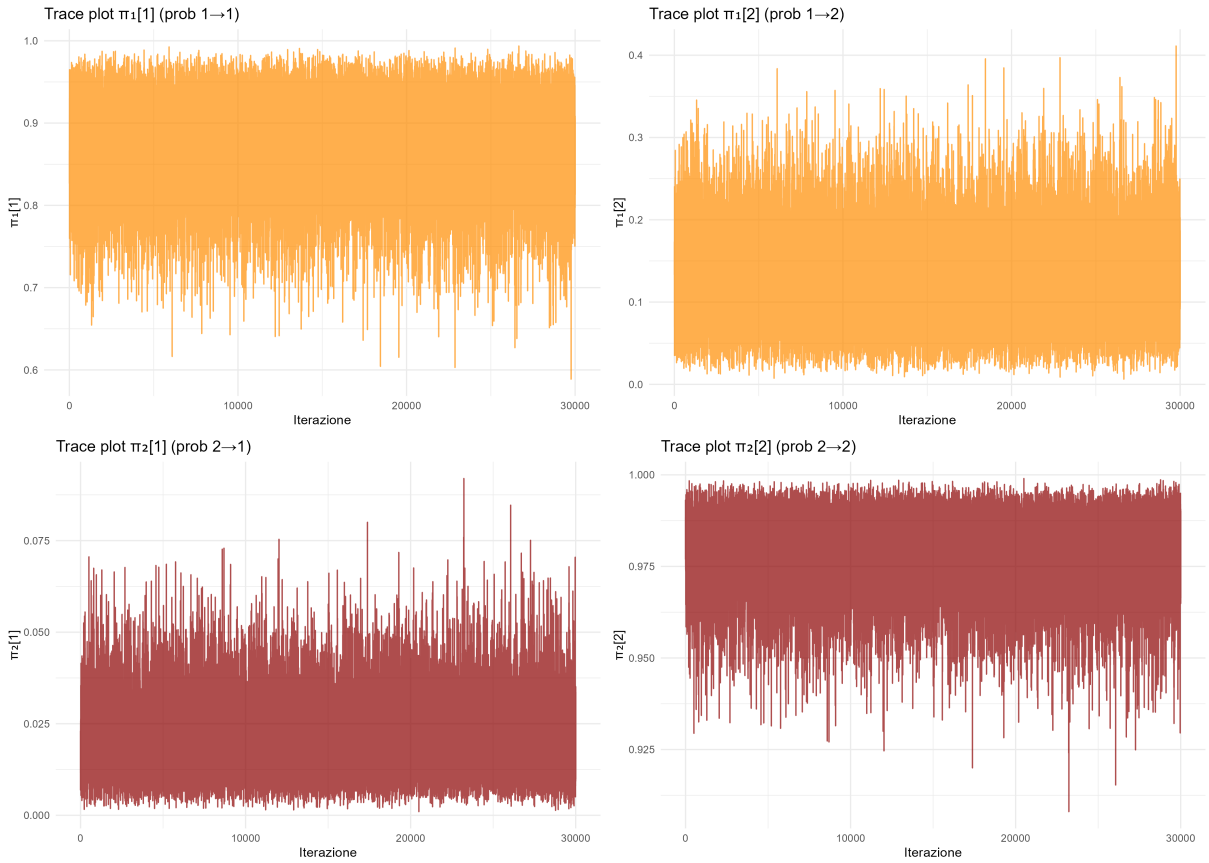


Figura 19: Traceplots delle probabilità di transizione π.

8.2 Interpretazione Fisica dei Parametri di Emissione

L'esame delle stime puntuali delle medie (μ_k) e, ancor più significativamente, delle matrici di covarianza (Σ_k), ci permette di caratterizzare geometricamente e funzionalmente i due stati latenti identificati. Le stime a posteriori complete sono riportate nella Tabella 2.

Tabella 4: Effective Sample Size (ESS) per i parametri del modello

Parametro	**ESS (su 30.000 iter.)**
Medie (μ)	
μ_{1x}	30.000
μ_{1y}	18.418
μ_{2x}	27.409
μ_{2y}	25.453
Covarianze (Σ)	
Σ_1 (Cluster 1)	8.662 - 27.646
Σ_2 (Cluster 2)	12.026 - 28.679
Transizioni (Π)	
$\pi_{1\to\cdot}$	21.293
$\pi_{2\to\cdot}$	20.297

Stato 1 (Regime ad alta variabilità): Il centroide stimato si colloca in $\hat{\mu}_1 \approx (0.97, 1.08)$. L'elemento distintivo di questo stato è la struttura della covarianza: osserviamo una varianza estremamente elevata lungo l'asse X ($\hat{\Sigma}_{1[1,1]} \approx 0.81$), mentre la dispersione lungo Y è decisamente più contenuta (≈ 0.08). Una tale dispersione orizzontale suggerisce che, in questo stato, il cane non è stazionario ma copre attivamente un'area estesa, muovendosi prevalentemente lungo la direttrice longitudinale.

Stato 2 (Regime a bassa variabilità): Il centroide è localizzato in $\hat{\mu}_2 \approx (0.97, 0.78)$. A differenza del precedente, questo stato è caratterizzato da varianze prossime allo zero ($\hat{\Sigma}_{2[1,1]} \approx 0.012$ e $\hat{\Sigma}_{2[2,2]} \approx 0.026$). Una variabilità quasi nulla implica che la posizione del cane coincide quasi perfettamente con il valore medio μ_2 per tutta la durata della permanenza nello stato, identificando una localizzazione precisa e puntiforme nello spazio.

Tabella 5: Stime a posteriori dei parametri di emissione (Media e Intervalli di Credibilità 95%)

Parametro	**Stima Puntuale (Media)**	**IC (95%)**	**Interpretazione**
Stato 1 (Attivo)			
μ_{1x}	0.968	[0.664, 1.271]	Centroide disperso su X
μ_{1y}	1.077	[0.970, 1.177]	Centroide stabile su Y
$\Sigma_{1[1,1]}$ (Var X)	0.8077	[0.5023, 1.2961]	Alta variabilità (Movimento)
$\Sigma_{1[2,2]}$ (Var Y)	0.0838	[0.0465, 0.1471]	Variabilità moderata
Stato 2 (Fermo)			
μ_{2x}	0.971	[0.956, 0.986]	Localizzazione precisa
μ_{2y}	0.780	[0.758, 0.802]	Localizzazione precisa
$\Sigma_{2[1,1]}$ (Var X)	0.0123	[0.0102, 0.0149]	Varianza quasi nulla (Sosta)
$\Sigma_{2[2,2]}$ (Var Y)	0.0258	[0.0207, 0.0319]	Varianza quasi nulla (Sosta)

8.3 Dinamiche Temporali (Matrice π)

Le stime della matrice di transizione, riassunte nella Tabella 3, confermano la natura "viscosa" e persistente del processo, coerente con comportamenti etologici strutturati:

- **Persistenza del Riposo:** La probabilità di auto-transizione $\hat{\pi}_{2\to2} \approx 0.98$ indica un'inerzia fortissima dello Stato 2. Se il cane si trova in fase di riposo/sosta, è quasi certo che vi rimarrà anche nell'istante successivo.
- **Persistenza dell'Attività:** Anche lo Stato 1 mostra una elevata stabilità ($\hat{\pi}_{1\to1} \approx 0.88$), suggerendo che le fasi di movimento non sono eventi impulsivi o momentanei, ma costituiscono finestre temporali durature.

Tabella 6: Probabilità di transizione stimate a posteriori

Transizione	**Probabilità Media ($\hat{\pi}$)**	**IC (95%)**	**Significato**
Da Stato 1			
$1 \to 1$	0.879	[0.756, 0.964]	Alta persistenza del movimento
$1 \to 2$	0.121	[0.036, 0.244]	Probabilità di fermarsi
Da Stato 2			
$2 \to 1$	0.021	[0.006, 0.045]	Rara attivazione
$2 \to 2$	0.979	[0.955, 0.994]	Stato quasi assorbente (Sosta)

8.4 Conclusione Semantica: Definizione degli Stati Latenti

Integrando le evidenze geometriche (covarianze) con quelle dinamiche (transizioni), possiamo ora attribuire quel significato semantico oggettivo alle variabili latenti ipotizzato a priori:

- **Stato 1 = Movimento/Pattugliamento:** Definito non tanto dalla sua posizione media, quanto dalla magnitudo della sua varianza (Σ). Rappresenta un comportamento attivo di esplorazione o transito.
- **Stato 2 = Quiete/Stazionamento:** Definito dall'assenza di varianza significativa e dall'altissima auto-transizione. Rappresenta una fase di sosta prolungata in un punto di interesse specifico (es. casa del padrone).

Questa distinzione dimostra che l'HMM ha correttamente decomposto la traiettoria osservata in due regimi cinetici qualitativamente distinti (dinamico vs statico), validando pienamente l'ipotesi di dipendenza temporale e spaziale formulata in sede di analisi esplorativa.

9 Clusterizzazione della Traiettoria ($L = 2$)

Una volta caratterizzati i parametri del modello, siamo passati alla fase di classificazione operativa della traiettoria. Per ogni istante t, abbiamo stimato lo stato latente $\hat{z}_t$ (moda della posteriore marginale), proiettando la struttura statistica del modello nello spazio fisico e nel tempo.

9.1 Analisi Spaziale: Verifica della Topologia

La proiezione degli stati stimati sulla mappa geografica (Figura 20) fornisce la conferma visiva immediata di quanto emerso dall'analisi delle matrici di covarianza:

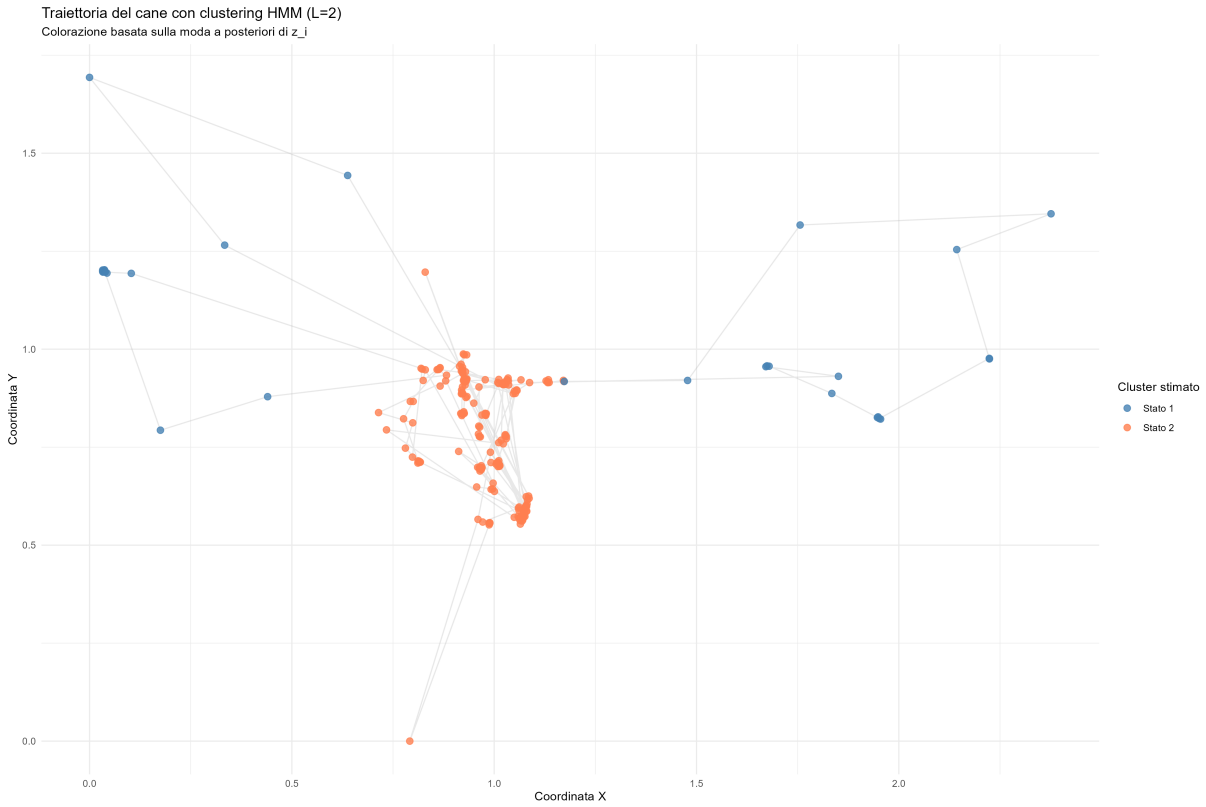


Figura 20: Traiettoria del cane con clustering HMM ($L = 2$). Colorazione basata sulla moda a posteriori di z_i.

- **Cluster 2 ("Casa Base"):** La nuvola di punti arancioni non è dispersa casualmente, ma collassa in un nucleo estremamente denso al centro del dominio. Questo riscontro grafico valida geometricamente la bassissima varianza stimata per Σ_2, identificando senza ambiguità l'area di stazionamento principale.
- **Cluster 1 ("Incursioni"):** I punti blu disegnano perfettamente le traiettorie di transito che si dipanano dal nucleo verso la periferia, confermando che lo Stato 1 cattura la totalità della dinamica di spostamento.

La clusterizzazione opera quindi una discriminazione efficace basata sulla densità locale, isolando il "centro" stabile dalla "periferia" di transito.

9.2 Analisi Temporale: Il valore della Memoria Markoviana

L'ispezione delle coordinate nel tempo (Figura 21) evidenzia il vero vantaggio dell'HMM rispetto a un clustering indipendente: la coerenza temporale.

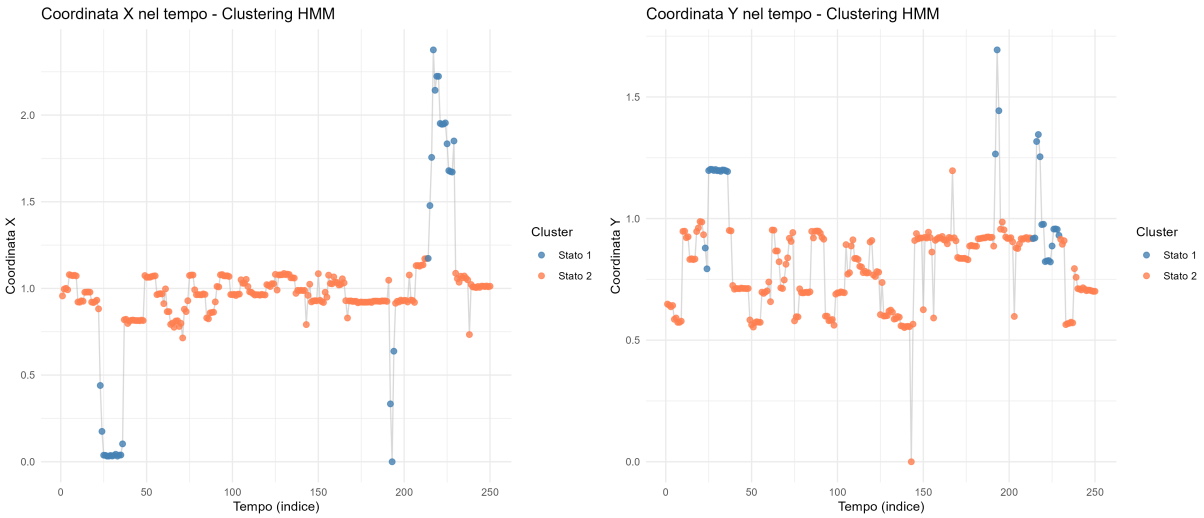


Figura 21: Coordinata X e Coordinata Y nel tempo con classificazione degli stati HMM.

Non osserviamo un'alternanza caotica degli stati, bensì lunghi blocchi continui di colore uniforme. Questo dimostra visivamente l'effetto della matrice di transizione Π: il modello sfrutta la "memoria" del processo per filtrare il rumore momentaneo, stabilizzando la classificazione.

Inoltre, la corrispondenza cinematica è perfetta: i segmenti classificati come Stato 2 coincidono sistematicamente con i "plateau" (linee piatte) delle coordinate, mentre lo Stato 1 cattura puntualmente tutti i "salti" (variazioni rapide).

Conclusioni Analisi In sintesi, l'analisi congiunta dei parametri stimati della sezione 8 e della clusterizzazione operativa di questa sezione conferma la piena validità del modello HMM nel descrivere il comportamento del soggetto. La netta distinzione statistica tra le matrici di covarianza trova un riscontro visivo immediato nella topologia della traiettoria, dove il modello ha separato con precisione il nucleo stazionario a bassissima varianza ("Casa Base", Stato 2) dalle fasi dinamiche di esplorazione periferica ("Incursioni", Stato 1). Inoltre, la struttura Markoviana ha garantito una ricostruzione temporale robusta, eliminando le fluttuazioni casuali e restituendo una sequenza di stati coerente, che descrive fedelmente l'alternanza reale tra le fasi di attività e i momenti di riposo.

10 Estensione del Modello a $L = 3$ Stati: Analisi delle Full Conditional e Implementazione

Nel passaggio da un modello a due stati ($L = 2$) a uno a tre stati ($L = 3$), abbiamo osservato che la struttura analitica delle distribuzioni condizionate complete (full conditional) rimane invariata nella sua forma funzionale, richiedendo tuttavia un necessario adattamento dimensionale per accogliere il terzo cluster.

Per quanto riguarda i parametri di emissione (μ_k, Σ_k), il calcolo per il terzo stato è analogo a quanto derivato per i primi due. Operativamente, come implementato nel codice, l'aggiornamento richiede il calcolo delle statistiche sufficienti specifiche per il nuovo gruppo (ovvero la cardinalità n_3, la somma dei dati e la somma dei quadrati degli scarti). Di conseguenza, la full conditional per μ_3 rimane una Normale Multivariata e quella per Σ_3 una Inverse-Wishart, mantenendo la stessa struttura algebrica degli stati 1 e 2. La

complessità computazionale del Gibbs Sampler aumenta quindi linearmente, comportando semplicemente l'aggiunta di un blocco di campionamento indipendente per il terzo componente.

Un adattamento dimensionale più sostanziale si riscontra nell'aggiornamento della matrice di transizione. Per il generico vettore π_k (k-esima riga della matrice di transizione), la distribuzione a posteriori si conferma essere una Dirichlet, ma il vettore dei parametri si estende ora a tre dimensioni. Nel codice, la funzione di conteggio (`table`) genera ora una matrice di transizione osservata di dimensione 3×3; il campionamento avviene pertanto tramite estrazione da una Dirichlet aggiornata con i conteggi di transizione verso tutti e tre gli stati possibili (n_{k1}, n_{k2}, n_{k3}).

Infine, le modifiche strutturali più significative riguardano l'Algoritmo di Viterbi (Forward-Backward). L'introduzione del terzo stato latente ridefinisce la topologia del modello, implicando due adeguamenti implementativi:

- **Espansione della matrice Forward:** La matrice delle probabilità filtrate (`alfa_matrice`) è stata estesa per accogliere una terza colonna, necessaria per memorizzare la densità marginale condizionata del nuovo stato.
- **Estensione del dominio di iterazione:** Il calcolo ricorsivo della variabile $\alpha_t(k)$ richiede ora che i cicli scorrano su tre valori sia per lo stato corrente k che per quello precedente k_{t-1} (entrambi in $\{1, 2, 3\}$). Questo garantisce che la probabilità marginale integri correttamente i contributi di tutte le possibili transizioni in ingresso.

Questa logica si riflette specularmente nella fase di backward sampling: la presenza del terzo stato amplia il supporto della distribuzione discreta da cui estrarre il vettore latente, come evidenziato dalle istruzioni di campionamento (`sample(1:3, ...)`) che ora valutano le probabilità di transizione verso un futuro z_{t+1} che può assumere tre valori distinti.

10.1 Diagnostica del Modello a 3 Stati ($L = 3$)

L'algoritmo MCMC è stato eseguito mantenendo le specifiche del caso precedente: $B = 50.000$ iterazioni totali, con un burn-in conservativo di 20.000, producendo un campione finale di 30.000 osservazioni utili per l'inferenza.

10.1.1 Convergenza, Mixing e Label Switching

L'ispezione visiva delle traiettorie delle catene (traceplot) conferma la robustezza dell'algoritmo anche in questo scenario a maggiore complessità:

- **Stazionarietà e Mixing:** Come si evince dai grafici relativi ai parametri di media (μ) e alle probabilità di transizione (π), le catene esibiscono un comportamento di mixing eccellente. I traceplot assumono la caratteristica conformazione desiderata, oscillando rapidamente attorno ai valori medi senza evidenziare trend di deriva o periodicità, sintomo di una esplorazione efficace della distribuzione a posteriori.
- **Assenza di Label Switching:** L'analisi dei traceplot delle coordinate μ_x e μ_y scongiura questa ipotesi: le tre catene rimangono perfettamente segregate e distinte sui propri livelli medi per l'intera durata della simulazione. Nello specifico, la

coordinata X del Cluster 3 oscilla stabilmente attorno a valori elevati ($\mu_{3,x} \approx 2.0$), ben separata da quelle del Cluster 2 (≈ 1.0) e del Cluster 1 (≈ 0.2). L'assenza di sovrapposizioni o salti tra questi livelli conferma che il modello è strutturalmente identificato e non necessita di procedure correttive.

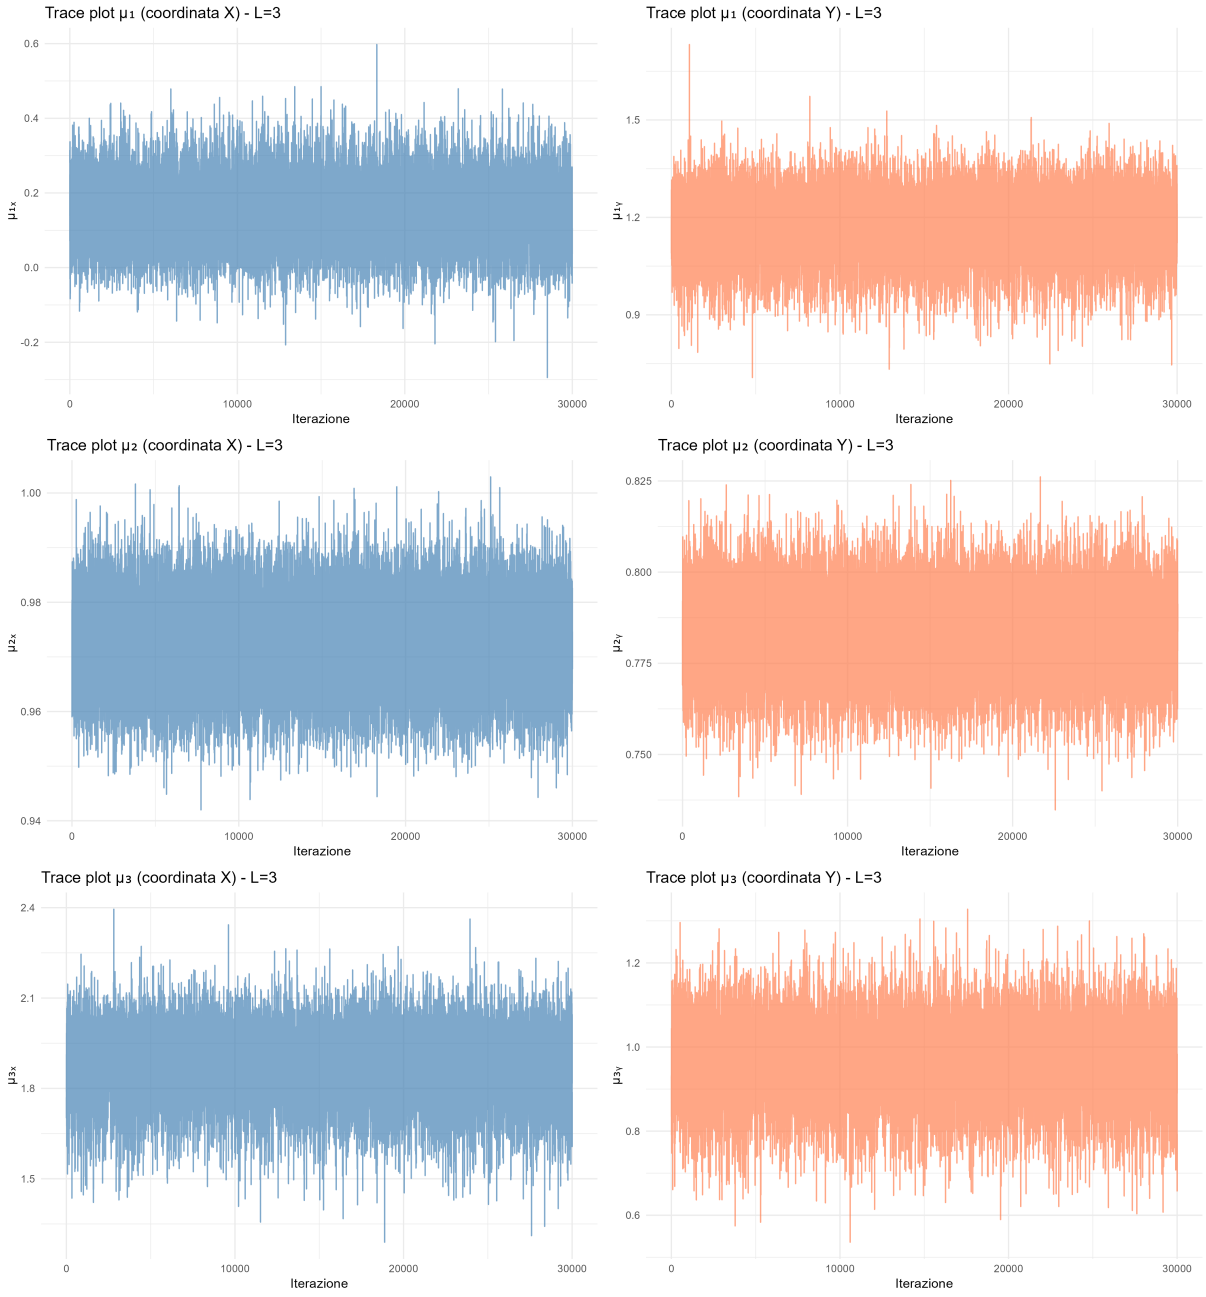


Figura 22: Traceplots dei parametri μ per il modello a 3 stati ($L = 3$).

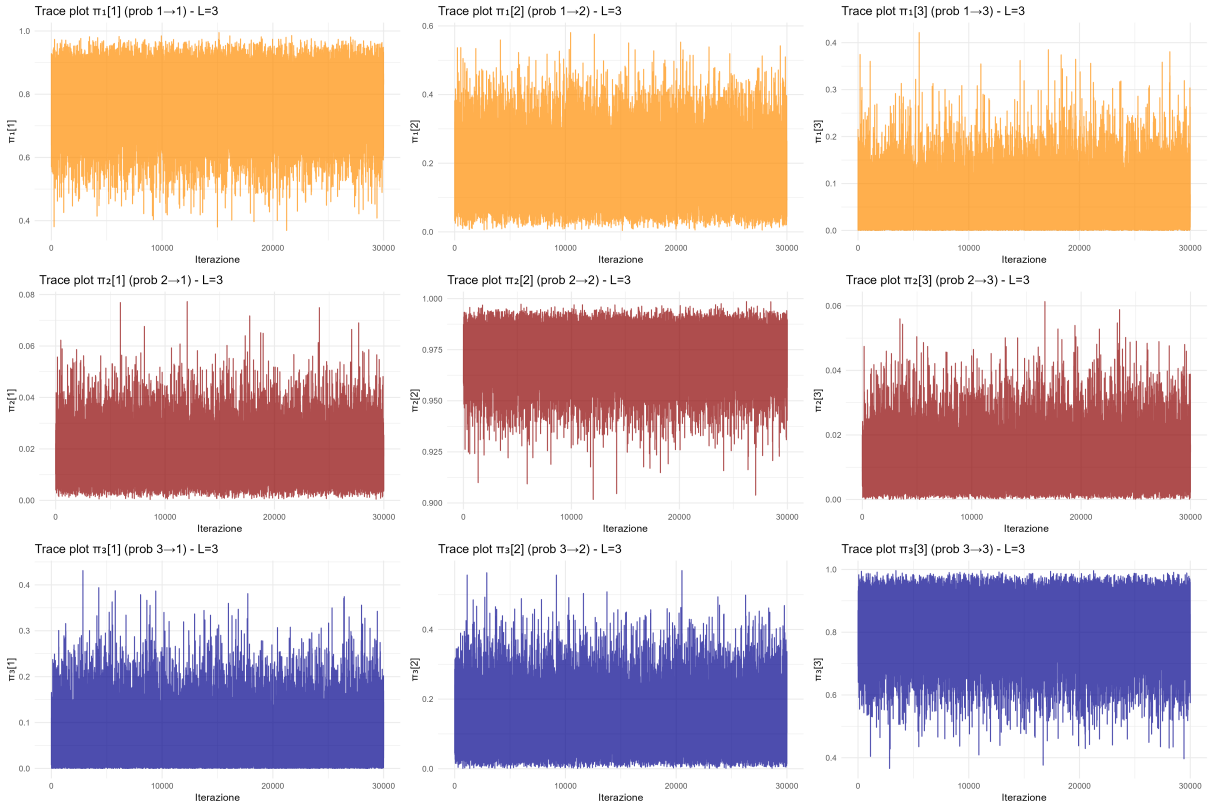


Figura 23: Traceplots delle probabilità di transizione π per il modello a 3 stati ($L = 3$).

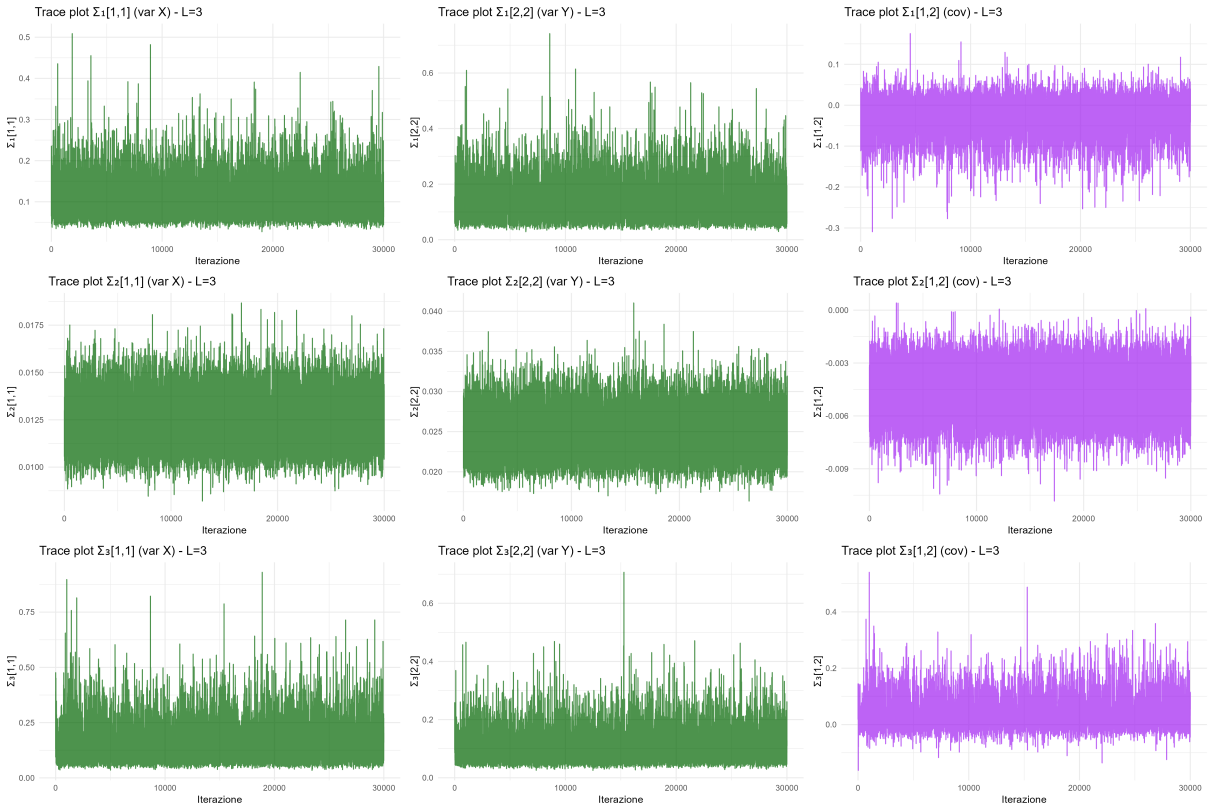


Figura 24: Traceplots dei parametri Σ per il modello a 3 stati ($L = 3$).

10.1.2 Efficienza del Campionamento (ESS)

L'efficienza computazionale, misurata tramite l'Effective Sample Size (ESS), si mantiene su livelli estremamente elevati, corroborando il vantaggio decisivo dell'utilizzo dell'algoritmo di Viterbi (Forward-Backward) per il campionamento in blocco delle variabili latenti.

Come dettagliato nella Tabella 4, su 30.000 iterazioni conservate, l'ESS per la maggior parte dei parametri è prossimo alla dimensione nominale del campione (si notino i valori ≈ 28.000 per il Cluster 2). Sebbene si osservi una lieve eterogeneità — con il Cluster 3 che mostra un mixing leggermente inferiore ($\approx 5.000 - 8.000$) rispetto al robustissimo Cluster 2 — i valori rimangono comunque di ordini di grandezza superiori alla soglia minima richiesta per un'inferenza affidabile (400-500).

Tali risultati ci permettono di procedere con confidenza alla caratterizzazione semantica dei tre stati, basando le nostre conclusioni su campioni statisticamente indipendenti.

Tabella 7: Effective Sample Size (ESS) per il modello $L = 3$ (su 30.000 iterazioni)

Cluster (Stato)	**Parametro**	**Elemento**	**ESS**	**Note**
Cluster 1	Media (μ_1)	$\mu_{1,x}$	15.738	
		$\mu_{1,y}$	11.290	
	Covarianza (Σ_1)	Var(X)	13.563	
Cluster 2	Media (μ_2)	$\mu_{2,x}$	28.381	Cluster meglio definito
		$\mu_{2,y}$	29.068	
	Covarianza (Σ_2)	Var(X)	28.892	
Cluster 3	Media (μ_3)	$\mu_{3,x}$	8.831	Mixing più lento ma adeguato
		$\mu_{3,y}$	11.246	
	Covarianza (Σ_3)	Var(X)	5.287	
Transizioni	$\pi_{k\to k}$ (Diag.)	$1 \to 1$	19.189	
		$2 \to 2$	25.153	
		$3 \to 3$	19.808	

10.2 Interpretazione Fisica dei Parametri e Dinamiche ($L = 3$)

Confermata la convergenza statistica, procediamo all'interpretazione semantica dei tre stati latenti. L'analisi congiunta delle stime puntuali delle medie (μ_k) e della distribuzione spaziale dei cluster rivela una riorganizzazione significativa della struttura del modello rispetto al caso $L = 2$, passando da una logica puramente comportamentale a una logica territoriale.

10.2.1 Caratterizzazione degli Stati Latenti

Osservando i centroidi stimati riportati in Tabella 5 e le relative matrici di covarianza (Tabella 6), possiamo etichettare i tre stati come segue:

- **Stato 2 ("Casa Base"):** Questo cluster eredita le caratteristiche dello stato "statico" del modello precedente. È caratterizzato da un centroide posizionato centralmente ($\hat{\mu}_2 \approx 0.97$ su X) e da una varianza estremamente ridotta ($\sigma_x^2 \approx 0.012$). Rappresenta univocamente il nucleo denso di punti dove il cane trascorre la maggior parte del tempo in stasi (riposo o presidio).

- **Stato 1 ("Pattugliamento Ovest"):** A differenza del modello $L = 2$, dove tutto il movimento era aggregato, qui isoliamo una specifica regione. Il centroide si colloca nettamente a sinistra del nucleo centrale ($\hat{\mu}_{1,x} \approx 0.14$). I punti classificati in questo stato corrispondono alle escursioni verso la zona a basse coordinate X.

- **Stato 3 ("Pattugliamento Est"):** Questo nuovo stato cattura le escursioni nella direzione opposta, con un centroide spostato decisamente verso destra ($\hat{\mu}_{3,x} \approx 1.87$).

È fondamentale notare che, mentre lo Stato 2 è definito da una proprietà cinematica (l'assenza di movimento, indicata dalla varianza minima), gli Stati 1 e 3 sono discriminati da una proprietà geografica. Entrambi rappresentano "movimento" (alte varianze: ≈ 0.10 e 0.14), ma il modello li distingue in base alla destinazione dello spostamento.

Tabella 8: Centri dei Cluster (μ) - Stime a Posteriori

Cluster	**Coordinata X (Media [IC 95%])**	**Coordinata Y (Media [IC 95%])**
1 (Ovest)	0.145 [-0.008, 0.305]	1.168 [0.979, 1.337]
2 (Centro)	0.972 [0.957, 0.987]	0.783 [0.762, 0.804]
3 (Est)	1.873 [1.637, 2.067]	0.964 [0.785, 1.123]

Tabella 9: Matrici di Covarianza (Σ) - Variabilità del Movimento

Cluster	**Var(X)** σ_x^2	**Cov(X,Y)** σ_{xy}	**Var(Y)** σ_y^2
1	0.1004	-0.0244	0.1274
2	0.0124	-0.0046	0.0246
3	0.1410	0.0327	0.0993

10.2.2 Analisi delle Transizioni: Il Ruolo di "Hub" Centrale

La matrice di transizione stimata (Tabella 7) conferma la struttura logica del movimento. La diagonale dominante ($\hat{\pi}_{kk} > 0.78$ per tutti gli stati) ribadisce l'inerzia comportamentale. Un aspetto cruciale emerge analizzando le probabilità fuori diagonale: lo Stato 2 funge da vero e proprio hub comportamentale. Le probabilità di transizione diretta tra gli estremi sono minime ($\hat{\pi}_{1\to3} \approx 0.049$ e $\hat{\pi}_{3\to1} \approx 0.053$). Al contrario, le probabilità di rientrare verso il centro sono decisamente superiori ($\hat{\pi}_{1\to2} \approx 0.17$ e $\hat{\pi}_{3\to2} \approx 0.12$). Questo indica che il cane raramente passa direttamente dall'estremo Ovest all'estremo Est; tipicamente, ogni escursione termina con un ritorno alla "Casa Base" prima che ne inizi una nuova in direzione opposta.

Tabella 10: Matrice di Transizione (π) - Probabilità Medie

Da A	**Stato 1 (Ovest)**	**Stato 2 (Base)**	**Stato 3 (Est)**
Stato 1	0.781	0.171	0.049
Stato 2	0.016	0.973	0.011
Stato 3	0.053	0.124	0.823

10.3 Clusterizzazione della Traiettoria e Confronto Modelli

L'applicazione del modello a tre stati alla serie storica delle coordinate ci offre una chiave di lettura molto più ricca del comportamento del soggetto.

10.3.1 Analisi Temporale della Clusterizzazione

I grafici temporali mostrano una clusterizzazione estremamente pulita e coerente con la storia osservata (Figura 25):

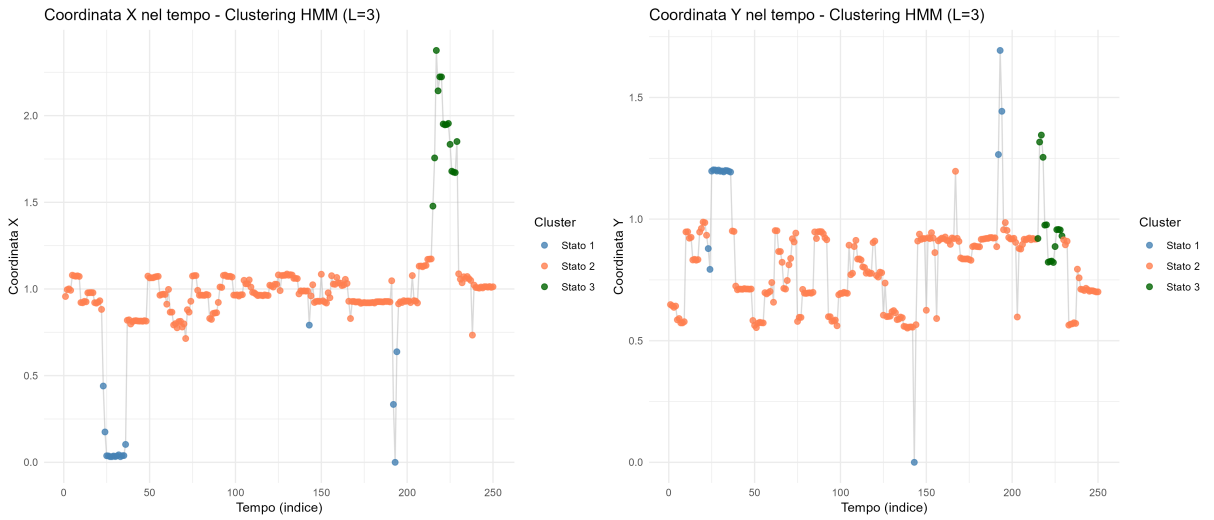


Figura 25: Coordinata X e Coordinata Y nel tempo con classificazione HMM ($L = 3$).

- **Fase Iniziale ($t < 50$):** Il modello cattura la rapida incursione verso la zona a bassa coordinata X classificandola come Stato 1 (Ovest).
- **Fase Centrale:** Segue un lungo periodo di stazionamento attorno alla base, correttamente identificato come Stato 2 (Centro), interrotto solo da brevi movimenti locali.
- **Fase Finale ($t > 200$):** In corrispondenza del picco nella coordinata X, il modello attiva prontamente lo Stato 3 (Est), distinguendo questa escursione dalla precedente.

Anche con $L = 3$, la coerenza temporale è preservata: non vi è traccia di instabilità nella classificazione, ma solo blocchi temporali solidi che descrivono azioni compiute.

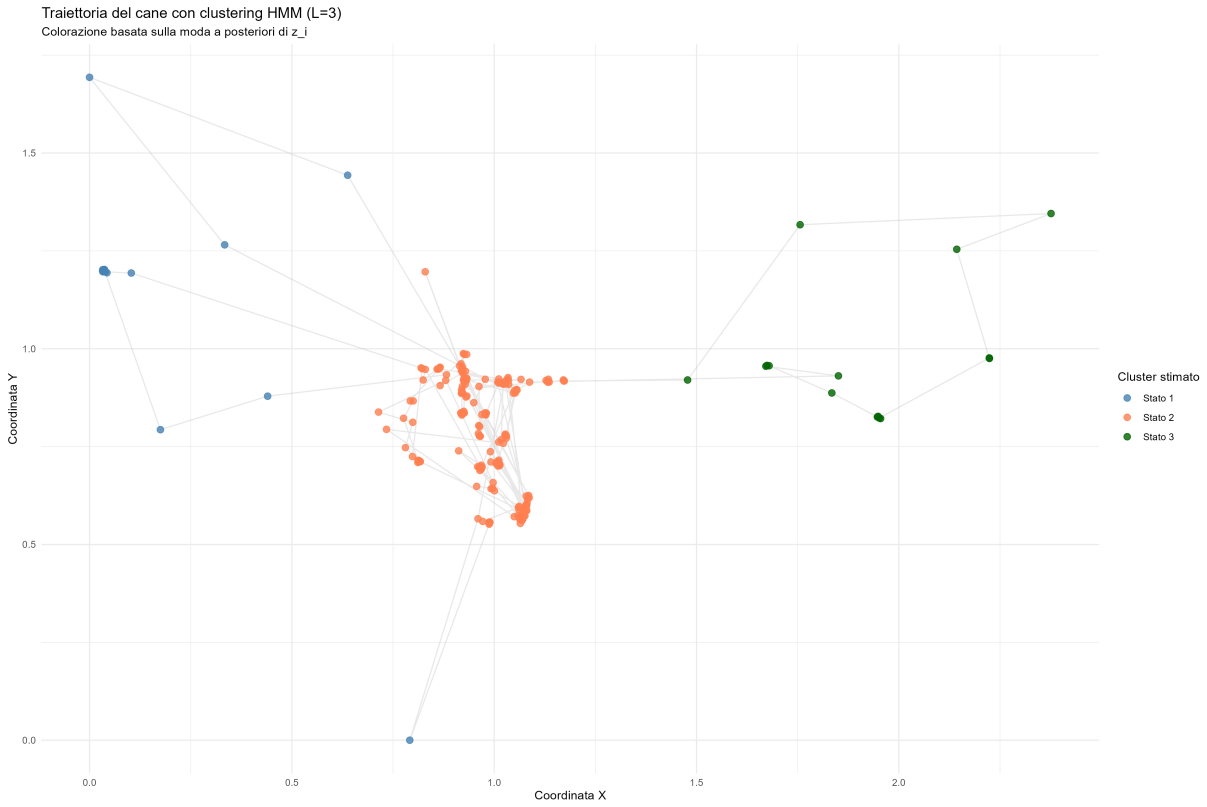


Figura 26: Traiettoria del cane con clustering HMM ($L = 3$).

10.3.2 Confronto Critico: $L = 2$ vs $L = 3$

La domanda cruciale è se l'aumento della complessità abbia portato a un reale guadagno informativo. La risposta è affermativa e si fonda su una distinzione qualitativa dell'informazione estratta:

- **Il Modello $L = 2$ (Discriminazione Comportamentale):** Rispondeva alla domanda "Cosa sta facendo il cane?". Distingueva efficacemente tra Stasi (riposo) e Attività (movimento), ma "appiattiva" tutto il movimento in un unico cluster eterogeneo, rendendo indistinguibile un'uscita a Est da una a Ovest.
- **Il Modello $L = 3$ (Discriminazione Spaziale):** Risponde alla domanda "Dove sta andando il cane?". Pur mantenendo la capacità di identificare la stasi (Stato 2), ha raffinato la componente di attività decomponendola in due macro-regioni funzionali distinte.

Conclusione: Mentre il modello a 2 stati è sufficiente per un'analisi puramente comportamentale (riposo/movimento), il modello a 3 stati si rivela indispensabile per un'analisi territoriale. Esso ha permesso di scoprire che il movimento del cane non è un girovagare isotropo, ma è strutturato attorno a (almeno) due zone di interesse specifiche situate ai lati opposti della tana. La "Casa Base" funge da baricentro gravitazionale, mentre gli Stati 1 e 3 identificano specifici corridoi di pattugliamento. L'introduzione del terzo stato non è quindi un mero artificio statistico, ma riflette una reale struttura bimodale nella distribuzione spaziale delle attività del cane.